



西安交通大学
XI'AN JIAOTONG UNIVERSITY

2026 年中国研究生数学建模竞赛
F 题论文

算力约束下大语言模型训练资源的 分层配置与能力前沿分析

参赛队编号：〔待填写〕

参赛学校：〔待填写〕

参赛队员：〔待填写〕

封面信息待参赛队按官方模板核对应后定稿

算力约束下大语言模型训练资源的分层配置与能力前沿分析

摘要

有限算力下的大语言模型训练需要联合决定模型规模、训练数据量、语料质量与领域配比，但题给数据分别来自文本信号、配方试验、标度样本和开放模型记录，不能把不同量尺直接视为一次受控实验。本文建立“质量代理与组成配比—质量条件标度律—成本约束优化—Loss 到能力的桥接”分层框架。问题一对 A1—A3 的 272,505 条文本信号构造四组等权质量代理，以 512 个 1M 配方训练 17 域 ALR 二阶多任务 ElasticNet；在既定 1M 配方集上 pooled RMSE 为 0.2543，较 Ridge 的 0.2702 降低 5.86%，但 1B 的 13 个验证域中有 5 个退步。问题二用 B1 估计 N-D 主项、B6 估计 $Q_B \times N$ 条件项，B6 留参数组 RMSE 由加性质量模型的 0.08144 降至 0.05235；该结论限于 B6/B7 半合成机制。问题三将训练、质量处理和上下文成本纳入约束，解析消去 D 后求解二维规划；在 10^{24} FLOPs、三倍观测上界的条件情景中， $N=35.897B$ 、 $D=899.68B$ 、 $Q_B=1$ 、 $Loss=1.9794$ ，预算使用率为 22.35%。问题四以 45 个严格匹配的开放权重模型构造六基准能力指数，Loss—能力单调桥接的家族分组 RMSE 为 11.864 分；12/24 月结果只作为冻结于 2025-01-31 原点的条件情景。分层建模给出了可复核的选择与外推边界，同时表明 Q_A 与 Q_B 的量尺映射、配比跨规模幅度及长期能力数值仍需新数据校准。

关键词： 大语言模型；数据质量；组成数据；标度律；算力配置；能力前沿

1 问题重述

有限算力下的预训练配置需要同时决定模型参数量 N 、训练 Token 数 D 、数据质量 Q 及领域配比 p 。经典标度律描述 N 与 D 对验证损失的影响[4]；数据筛选与配比研究进一步提示训练语料结构的重要性[2, 3, 6]。然而，本题的质量信号、配方试验、标度样本和开放模型历史记录分别来自 A、B、C 三组附件。它们的损失口径、质量量尺及规模支持范围不同，因此需要将可估计的模块与条件连接明确区分。

本文以验证 Loss 为前三问的目标量，以六项 Benchmark 均值为第四问的能力量。先在 A 组定义文本质量代理并学习配比响应，再在 B 组估计条件损失函数，以题设成本求解资源配置，最后用 C 组检验 Loss - 能力桥接及历史前沿。对于未共同观测的 $Q_A \leftrightarrow Q_B$ 与配比跨规模幅度 λ_p ，仅设置显式情景，不将其作为已估计参数。

本文贡献概括为三点：

1. 建立可追溯的质量与配比评价。对 A1 - A3 共 272,505 条信号记录使用固定的四组等权质量规则；在 A6/A7 的 1M 配方集上，二阶 ALR 多任务 ElasticNet 相比二阶 ALR Ridge 的 pooled RMSE 降低 5.86%，同时保留可用于下游的组成数据差分接口。
2. 构建条件质量标度律与预算配置模型。在 B6 留参数组上， $Q_p \times N$ 项相比加性质量项将 RMSE 降低约 35.7%；在 10^{19} 、 10^{22} 、 10^{24} FLOPs 下给出观测域、三倍边界及自由外推的配置剖面，并核对预算与最优性条件。
3. 建立能力口径与跨问证据链。对 45 个严格匹配的开放权重模型计算六基准能力指数；C6 的 Loss - 能力桥接在家族分组验证中 RMSE 为 11.864 分，并对历史前沿与 12/24 个月情景分别标明样本条件和预测原点。

1.1 竞赛任务的共同目标

题目要求从数据价值、训练损失、算力预算和能力演化四个层面回答同一资源决策问题。本文将前三问的目标统一为给定条件下验证 Loss 的最小化；第四问将 Loss 与六项 Benchmark 能力分数区分，再用可检验的桥接模型连接。对配比、质量与规模未共同观测的部分，仅给出明示条件的情景结果。

1.2 相关工作与本文定位

参数量与训练数据量之间的配置关系是预训练资源分配的基础。Hoffmann 等[4]通过规模实验讨论给定计算预算下的参数和数据选择，Pythia 工作[5]为同一模型族的训练轨迹分析提供了公开样本。此类研究支持用低维幂律刻画规模效应，但具体系数依赖语料、模型族和验证损失口径。本文因而只用 B1 估计统一的 $N - D$ 主项，并将 B2/B4/B5 作为未经校准的跨来源比较；组内误差和组外误差分别报告，避免把同一训练轨迹上的精细拟合直接解释为跨族精度。

数据维度同时包含样本质量与领域组成。DataComp-LM[2]强调数据集设计对语言模型训练的重要性；RegMix[3]与 Data Mixing Laws[6]提示小规模配比实验可为候选训练配方提供预测信息。本文的 A 组质量信号与配比 Loss 并不构成“质量筛选—模型再训练”的成对实验，因此四组等权 Q_A 是可审计的筛选代理，而非已校准的性能收益。另一方面，17 域占比之和为一，改变一个领域必然改变其他领域；对数比坐标[1]用于表达这种相对结构。与直接把 17 个比例独立输入回归相比，该参数化更符合配方数据的几何约束，并允许在固定参考配方下输出可比较的 Loss 差分。

从预训练损失到下游能力还需定义统一的测量对象。已有研究讨论训练量与任务表现的关系[7]，算法进展研究[8]则为规模之外的时间项提供了分析动机。本题 C 组记录包含不同能力任务、发布时间及开放权重口径，不能用单一分数替代全部任务表现。因此本文先固定六项基准的等权能力定义，再以 C8 逐任务记录检查一致性，并对 C6 桥接使用模型家族隔离评价。未来能力只作为冻结原点下的条件情景表达，确保历史回顾与当下预测在时间含义上清楚区分。

2 问题分析

2.1 问题一：质量代理与配比响应

文本信号给出可审计的筛选维度，却没有人工质量真值；领域占比满足总和为一，任一域变化都伴随其他域变化。因此先把 22 项信号变为四组效用，再用对数比坐标学习配比与 13 个验证域 Loss 的相对关系。输出为质量代理 Q_A 、配比预测函数及相对参考配方的 Loss 差分。

2.2 问题二：条件损失函数

参数规模和 Token 数的主效应由 B1 同族轨迹估计，质量响应由 B6 的半合成样本估计。需要分别检查同机制留组、新输入点和异机制来源。问题一的配比模型可提供差分形状，但跨规模增益幅度未识别，故用显式 λ_p 情景连接。

2.3 问题三：成本约束规划

决策量 N 、 D 、 Q_B 和候选配比共同决定预测 Loss，三项成本之和受 FLOPs 预算限制。Loss 对 D 的单调性允许先解析确定给定 N 、 Q_B 时的最大可用 D ，再以二维搜索处理质量投入和规模。高预算结果需与 B1 观测域及扩展上界并列报告。

2.4 问题四：能力测量与前沿

验证 Loss 不是 Benchmark 能力，必须先固定统一能力定义，再用 C6 样本检验单调桥接。历史前沿、家族分组误差与未来情景是三类不同证据；未来值固定 2025-01-31 原点，仅描述算力增长和剩余时间项设定下的可能轨迹。

2.5 总体建模框架

图 1 的实线为代码直接读取或同一数据源内估计；虚线为未共同观测的条件连接。P1 的配比模型系数嵌入 P2，P2 参数直接进入 P3，P3 方法在 P4 的机制情景中重算； $Q_A \rightarrow Q_B$ 量尺及 $\lambda_p(N)$ 没有实证锚点，不进入确定结论。




图 1 多源证据下的四问分层建模框架

3 模型假设

3.1 数据与测量

同一附件及同一评价口径内的样本可用于该层模型估计。A、B、C 不视为同批联合受控训练；A 组 Q_A 只表示固定规则下的相对质量代理，B 组 Q_B 只表示 B6/B7 质量机制。13 个配比响应域、六项能力任务在各自评价中按既定权重汇总，不暗示所有任务价值相同。

3.2 成本与规划

题设训练成本与注意力成本随 N 、 D 单调增长，质量处理成本由所选 $g(Q_B)$ 决定。固定 N 、 Q_B 和配比时，增加 D 可降低选定损失函数；可行域的 N 、 D 上下界及 $Q_B \in [Q_0, 1]$ 由情景指定。预算未用尽可由硬上界激活造成，不强制人为耗尽。

3.3 外推与能力情景

$E0$ 、 $E1$ 、 $E2$ 分别表示 $B1$ 观测上界、三倍上界和自由外推，是证据等级而非统计置信区间。未来能力情景的算力增长率与时间项只作条件输入；不把样本外目标日期后的信息回填到冻结原点。

4 符号说明

表 1 主要符号、单位与解释

符号	含义	单位或范围
N	非嵌入参数规模	十亿参数 B
D	训练 Token 数	十亿 Token B
Q_A	A 组规则质量代理	0—1，无人工真值校准
Q_B	B 组半合成质量列	0—1，不与 Q_A 直接等同
p 、 p_0	17 域配比及参考配比	单纯形，和为 1
Δ_p	P1 模型相对 p_0 的 Loss 差	验证 Loss 单位
λ_p	配比跨规模幅度	条件情景参数
L	验证集预训练损失	越低越好
C 、 C_{tot}	可用及使用算力	FLOPs
$g(Q_B)$ 、 Q_0	质量成本函数及基线质量	情景给定
L_{ctx}	上下文长度	Token
S	六项 Benchmark 能力指数	0—100 分，越高越好
R_s	情景 s 下相对 oracle 的后悔值	Loss 单位

5 数据预处理与基础分析

5.1 数据层次与单位

$A1 - A3$ 含文本质量信号； $A4/A5$ 提供 512 个 1M 配方及 13 个验证域 Loss，既定 1M、60M、1B 配方集用于回顾性评价。 $B1$ 含 1,176 条参数 - 数据规模轨迹； $B6/B7$ 提供半合成质量响应； $C1$ 、 $C4$ 、 $C6$ 、 $C8$ 分别用于能力记录、算力元数据、Loss - Benchmark 桥接和逐任务核对。A、B、C 并非同一批联合控制训练，本文据此采用分层估计。

标度模型中的 N, D 均以十亿计，计算成本使用 FLOPs； Q_A 是 A 组信号代理， Q_B 是 B 组质量列，二者均在 $[0, 1]$ 内，但量尺不直接互换。 $\mathbf{p} = (p_1, \dots, p_{17})$ 满足 $p_i \geq 0$ 、 $\sum_i p_i = 1$ 。验证 Loss 越低越好，能力指数越高越好。

证据层	主要数据	本文用途
文本信号	$A1 - A3$	固定规则的质量代理及冲突标记
配方响应	$A4 - A15$	1M 训练、既定规模比较；10B/70B 为估算标签
规模与质量	$B1 - B8$	规模律、半合成质量项及来源机制诊断

证据层	主要数据	本文用途
能力记录	C1 - C8	开放模型能力指数、桥接与时间情景

表 2 四问数据层次及作用

层次	样本与内容	建模作用	独立性与限制
A1—A3	272,505 条质量信号记录	Q_A 的规则代理	无人工质量真值
A4/A5	512 条 1M 配方运行, 17 输入域、13 验证域	配比模型训练	既定测试集为回顾性比较
B1	1,176 条同族 N-D 轨迹	经典标度律	跨族原始 Loss 不同口径
B6/B7/B8	质量响应及异机制诊断	Q_B 条件项	半合成, B8 不参加选型
C1/C4/C6/C8	榜单、元数据、桥接与逐任务记录	能力指数、桥接、前沿	严格匹配只有 45 模型

5.2 验证协议与证据等级

配比模型在 A4/A5 内进行五折嵌套交叉验证, 超参数、零替换和标准化均由训练折决定; 既定跨规模集只用于回顾性评价。B1 按完整参数规模组留出, B6 按参数组留出, B7 用去重后的新输入点; B2/B4/B5 报告未经目标来源标签校准的原始误差。预算模型检查约束可行性、边界和数值最优性。能力桥接按模型家族分组验证, 时间情景固定预测原点。

项目内 `selected_lineage.json` 记录 P1 模型嵌入 P2、P2 进入 P3 与 P4 摘要的 artifact hash。数值复核优先采用选定链; 早期 V1 结果仅作为候选历史。A6/A7 与 60M 共享配方, 所以二者不是两个独立配比分布; B7 是 B6 去重后的新输入点, B8 仅检验机制冲突; C8 的逐任务相关属于同源测量核对。

5.3 样本、标签与评价对象的对应

质量信号在 A1、A2、A3 分别有 51,230、17,523、203,752 条记录, 总计 272,505 条。扩展样本的比较先剔除与 A1 重合的 ID, 再观察相同来源域的规则分数是否发生较大漂移; 这检验的是代理分数的定义稳定性, 而不是人工评价的一致性。22 项信号中有标量、列表及长尾计数, 必须先按字段规则取值和定向, 再用 A1 固定分位尺度归一, 不能让扩展集重估分位点后又声称分数可直接比较。规则与缺失处理在附录 A 逐项列出。

配比响应的训练单位是一次 1M 配方运行, 而不是单条文本。A4/A5 合计 512 个配方, 每个对应 17 维闭包比例和 13 个验证域 Loss。既定 A6/A7 1M 测试有 256 个配方, 60M 的 256 个配方与其共享配方设计, 1B 集有 64 个配方; 将 13 个响应展开为多行并不能把有效配方样本量乘以 13。自举以配方行为单位, 保持同一次运行的 13 个验证响应一起抽取, 避免虚增精度。10B/70B 的 Loss 是估算标签, 不进入最终模型胜负判断。

B1 的 1,176 行是同一模型族的训练轨迹, 同一参数规模下不同训练 Token 点彼此相关; 因此按完整 N 组留出比随机行划分更能检验规模泛化。B6 的 360 行用于拟合质量条件项, B7 去重后有 90 个新输入点评价, B8 与 B6 存在 160 组相同 N、D、Q_B 输入却有不同机制标签。B8 的用途是指出不可合并性, 不能为了增加样本量而并入常规质量回归。B2/B4/B5 的原始误差只与零样本口径对应; 来源校准表的前段标签必须计入信息使用。

C1 榜单有 4,576 条记录, 严格开放权重、实体匹配、六项任务完整这三道条件后, 主前沿只剩 45 个独立模型。C6 的 75 条 Loss—Benchmark 记录来自 23 个家族, 其中高可比 7 条同属一个家族; 随机行验证可能让相近模型同时进入训练与测试, 故采用家族隔离。C8 逐任务聚合检验能力指数的同源一致性, 不替代独立任务外部验证。四类样本单位从文本、训练运行、规模轨迹到模型实体逐层变化, 论文所有样本数与误差均按各自层次解释。

5.4 可追溯性与版本冻结

数值主链采用复赛选定 artifact: P1 的 ALR 多任务模型系数被 P2 推荐模型嵌入, P3 读取 P2 Model C, P4 的机制情景使用 P3 的求解函数按未来预算重算。rebuild/final_review/verification/selected_lineage.json 保存关键 SHA-256 和接口标记; 这能防止旧 V1 参数误入主文, 却不能证明跨数据来源的统计同质性。论文凡涉及 A/B/C 连接的句子, 都要说明是“直接代码读取”“同源拟合”“条件情景”还是“描述性比较”。这一标注是后文模型评价的基础。

6 问题一：数据质量评价与领域配比模型

本节保存质量代理构造的逐项规则、领域统计和冲突阈值核查。相关表格来自问题一已有数据审计; 它们用于复核代理定义, 不充当人工质量标签。

6.1 数据质量指标处理

A1、A2、A3 分别有 51,230、17,523、203,752 条。A1 涵盖七个质量域, A2/A3 扩展 arxiv/github。A1 与 A2 的重合 ID 有 1,419 个, 与 A3 的重合 ID 有 10,000 个; 分源评分时保留全量, 跨文件汇总时必须去重。A4-A15 的 12 个 CSV 均无缺失单元或重复 index; 配比行和与 1 的最大偏差约 0.004, 属于舍入误差, 入模前逐行归一。详见 [data_audit.csv](#)。

质量文件以 `.jsonl.xz` 流式逐行读取。ad_en、fluency_en 的二分类 logits 用正向类 softmax 概率压缩; ModernBERT 的 0-5 级 logits 用 softmax 期望除以 5; fineweb_edu 取单元元素; qurater 的四维按官方顺序等权平均。这些列表含义来自[数据集官方说明](#)。各字段采用 A1 固定参考分位点缩放, A2/A3 沿用同一标尺。长尾计数字段先作带符号的 `log1p`, 极值按 A1 1%/99% 截尾; 长度等“适中最好”字段用 1%/20%/80%/99% 梯形效用。缺失值以 A1 参考中位数补齐并记录。所有最终 z_k 均在 $[0,1]$, 越高代表该字段定义下越好。启发式方向见 [assumptions.md](#)。

6.2 四组等权质量代理与候选权重

令 z_{jk} 表示第 j 个样本经固定标尺处理后的指标。先把高度相关的 dsir_books、dsir_wiki、dsir_math 合成一个子项; 该三者的 Spearman 相关可达约 0.999, 相关矩阵条件数约 936.4 的单指标 VIF 量级。教育、可读性、洁净度、文本结构四组的组内子项等权, 组间等权:

$$Q_j = \frac{1}{4} \sum_{g=1}^4 S_{jg}, \quad S_{j, \text{educational}} = \frac{1}{5} (z_{\text{fineweb}} + z_{\text{reasoning}} + z_{\text{professionalism}} + z_{\text{qurater}} + \frac{z_{\text{dsir_books}} + z_{\text{dsir_wiki}} + z_{\text{dsir_math}}}{3}).$$

其余组的 S_{jg} 为组内指标均值。与此比较的增强候选为 [CRITIC 原始方法](#) 的离散度/相关性权重，以及四组得分去掉最高、最低后的鲁棒聚合。PCA 仅作结构分析，不把主成分自动解释为“质量”。A1 中第一、二主成分解释方差分别为 31.5%、18.7%；需要多于一个轴才可描述主要差异。相关矩阵、层次聚类 and VIF 进一步证明直接逐字段等权会重复计数。

方法	A1 域排名与基线 Spearman	样本分数平均绝对差
Q_baseline	1.000	0.0000
Q_critic	0.929	0.0279
Q_robust	0.964	0.0323
Q_penalty	1.000	0.0368
Q_hard	0.964	0.0097

CRITIC 与鲁棒方案提供有价值的敏感性对照，但在缺乏独立人工真值的条件下，没有足够依据说明更复杂权重更“正确”。主分析保留透明的 四组等权 Q 。四组权重的 Dirichlet 扰动排名见 [quality_weight_sensitivity.csv](#): arxiv 在 500 次扰动中位于前三的频率为 1.000，github 为 0.000。这说明指定权重邻域内的排序稳定，不构成外部质量真值验证。

6.3 领域级质量结果与稳健性

领域级主统计量取样本 Q 的均值，并同时输出中位数、10% 截尾均值和 Winsorized 均值。95% 区间由每个域按实际样本量重抽样 200 次的非参数 bootstrap 给出，属于给定评分规则后的抽样区间，不涵盖指标定义误差。A1 的均值与中位数域排名 Spearman 为 1.000。

A1 域	样本数	平均 Q	95% bootstrap CI	排名
arxiv	1419	0.7647	[0.7627, 0.7669]	1
commoncrawl	9640	0.7092	[0.7078, 0.7106]	2
stackexchange	10000	0.6959	[0.6945, 0.6974]	3
c4	10000	0.6894	[0.6877, 0.6911]	4
wikipedia	10000	0.6477	[0.6462, 0.6495]	5
book	171	0.6201	[0.6082, 0.6310]	6
github	10000	0.5750	[0.5736, 0.5766]	7

A2/A3 使用同一标尺；为避免把 A1 子样本重复当成独立证据，下表的扩展均值只用不在 A1 中的 ID:

域	A1 n	扩展中非重合 n	A1 Q	非重合 Q	差值
arxiv	1419	16104	0.7647	0.7616	-0.0031
github	10000	193752	0.5750	0.5741	-0.0009

解释边界：例如 arxiv 的 Q 较高，github 较低，是当前文本质量定义和统一阈值下的结果；代码语料和学术文本所需质量维度不同，不能把该排名等同于“训练价值”的绝对排序。

6.4 冲突定义与证据边界

离散冲突定义为：一维正向特征高于 A1 的 75% 分位，同时另一正向特征低于 25% 分位。事先指定三类：高 FineWeb 教育性与低无广告概率，高流畅度与低 ModernBERT 洁净度，高教育组得分与低可读性组得分。连续强度定义为 $I_j = \max_g S_{jg} - \min_g S_{jg}$ ；两者在不同层面反映冲突。

A1 域	n	任一冲突率 %	平均连续强度
arxiv	1419	5.07	0.2574
book	171	8.19	0.5384
c4	10000	7.79	0.4669
commoncrawl	9640	11.65	0.3724
github	10000	11.87	0.3676
stackexchange	10000	5.40	0.2653
wikipedia	10000	2.94	0.3831

A1 全体任一冲突率为 7.83%。阈值改为 20%/80%、25%/75%、30%/70% 时分别为 3.93%，7.83%，13.62%，因此“无冲突”会随阈值改变，不能给出脱离定义的唯一冲突率。A2 的 arxiv 冲突率为 5.72%，A3 的 github 为 11.15%；与 A1 同域模式相近。完整类型占比见 [conflict_summary.csv](#)。

比较两种消解： $Q_j^{\text{pen}} = [Q_j - 0.1I_j]_{[0,1]}$ ；若无广告概率低于 A1 第 10 分位，则 $Q_j^{\text{hard}} = 0.85Q_j$ ，否则为 Q_j 。强度惩罚使 A1 平均 Q 降低 0.0368，域排名与原模型的 Spearman 为 1.000。由于缺少独立人工标注，不能证明惩罚后的质量分优于原分，故主 Q 保持未惩罚版本，将冲突标记和强度单列供数据筛选。[manual_review_candidates.csv](#) 提供高低分与冲突样本的文本摘要供团队盲评；目前的浏览式检查不能替代正式人工验证。




图 2 质量代理的领域均值与条件区间

17 个训练域占比相加为一，原始比例连同截距直接进入回归会有确定线性依赖，且系数会随被省略域变化。以 `pile_cc` 为参照的 ALR 坐标将相对份额显式化；该域在本次训练中被选作稳定参照，并非具有特殊因果地位。二阶项允许局部替代与互补的预测曲率，但仅在观测配比支持附近解释。

6.5 组成约束、ALR 与多任务回归

本节使用选定链的 ALR 多任务 ElasticNet 结果。外部规模评价均为既定测试集的回溯性比较。

6.6 模型与统一验证协议

对 17 域配比 ($p_1, \dots, p_{17}$)，令 (r) 为 `pile_cc`，零替换 ($\cdot$)。ALR 坐标为

$[x_i, ir.]$

二阶特征 ((x)) 包含 16 个一次项、16 个平方项及 120 个两两交互项。选中候选将每个特征按训练折标准化，再拟合 13 响应的 MultiTask ElasticNet：

$[_{\{B, b\}}; Y - 1b^2 - BF^2 + B_{\{2, 1\}} + B_F^2, \dots]$

此处 ($B_{\{2, 1\}}$) 使一项二阶特征在 13 个输出上联合收缩，不意味着交互具有因果意义。全训练共有 136/152 个特征激活。

同一外层 `KFold(5, shuffle=True, random_state=20260924)`；每折训练内用 3 折选择候选超参。V2 外折规格取冻结的该折训练内结果；ElasticNet 和 PLS 的 ALR 参考域也取相应外折训练内选择，避免全训练参考域泄漏。最终模型在全部 A4/A5 上按 2×5 折重复 CV 选择后重拟合。所有标准化、样条结点和零替换用训练折信息计算。A6/A7、60M、1B 标签没有用于超参选择或拟合。

6.7 候选比较与模型选择

主指标为 A6/A7 1M 的 13 响应 pooled RMSE；训练内嵌套 OOF、60M/1B RMSE、MAE、排序、局部效应与重抽样为次指标。`problem1_model1_tournament.csv` 保存全部字段。

表 3 问题一候选模型比较

模型	嵌套 OOF	A6/A7 1M	60M	1B	判定
冻结 V2 二阶 ALR Ridge	0.334010	0.270179	1.595903	2.702111	冻结比较基线
二阶 ALR MultiTask ElasticNet	0.318377	0.254346	1.592424	2.688705	通过已登记的总体门槛
二阶 ILR Ridge	0.351029	0.282204	1.594570	2.656762	1M 主指标 RMSE 升高
二阶 ALR PLS	0.542107	0.480686	1.628226	3.156230	RMSE 较高
CLR 加性样条 Ridge	0.252219	0.208173	1.561406	2.735706	1M 专用候选；1B 总体 RMSE 升高

ElasticNet 对 V2 的配对方行 bootstrap：嵌套 OOF 的 RMSE 改善 +0.015632 [0.012255, 0.019270]；1M +0.015834 [0.010465, 0.021037]；60M +0.003479 [-0.001769, 0.008716]；1B +0.013406 [0.007823, 0.018795]。五个外折的 OOF RMSE 全部改善。1M 的 12/13 域 RMSE 改善，13 域平均 Spearman 从 0.945224 到 0.949352；1B 的配方平均 Loss 排序 Spearman 从 0.566667 到 0.657738，配对增益区间 [+0.040871, +0.158657]。

1B 的逐域权衡不可忽略。13 个验证输出中，有 8 个 RMSE 改善，5 个 RMSE 升高；其中以下 4 个 RMSE 升高的回溯性配对区间不跨零：

验证域	V2 RMSE	ElasticNet RMSE	相对恶化
arxiv	2.164819	2.188393	+1.09%
freelaw	2.647592	2.666397	+0.71%
pubmed_central	2.361867	2.382771	+0.89%
github	3.278836	3.319268	+1.23%

原先登记的替换门槛约束总体 60M/1B 非劣和排名、1M 主指标、嵌套 OOF、lpp 方向；ElasticNet 全部通过。因此其为已登记规则下的跨问胜出候选。若最终论文或应用把“任何验证域均不得损害”设为更强 Condition B，则该候选不能宣称全维优越，也应继续保留 V2 作为保守接口。不能事后把此逐域发现藏入 pooled 指标。




图 3 配比模型的训练内与跨规模 RMSE

CLR 样条在 1M 的单项误差更低，但 1B 的 pooled RMSE 相对 Ridge 退步；PLS 在主测试明显退步。最终采用 ElasticNet 是训练内、1M 主指标、60M/1B 总体、排序和局部效应的联合选择，不意味着所有输出域都改善。

6.8 逐域结果与局部敏感性

在训练配比均值处固定从 `pile_cc` 转移 1 个百分点到另一域，共 16 个局部方向。ElasticNet 的方向与 V2 在 15/16 个方向一致；唯一不一致是 `pubmed_abstracts` 的极小效应，V2 约 -0.000029 ，新模型约 $+0.000164$ 。对固定规格做 40 次训练行 bootstrap，仅 9/16 方向达到 $\geq 90\%$ 同号率。这些量是局部预测关联，不能当作真实再训练收益。

Q 的四组等权代理没有人工评分真值。现有 140 条盲评模板仍是空白；`manual_validation_results.csv` 为 0 行。使用 A1 的 51,230 条样本、7 个来源域做无监督敏感性；PCA 一因子得分的域均值排序与原 Q Spearman 为 0.25，熵权为 0.9286，组等权秩聚合为 0.8929；单因子 FA 未收敛，不能作为可靠得分。这些相关仅衡量定义变化造成的排名变化，不是质量有效性检验。因此继续保留四组等权 Q，不估计或宣称新权重更优。

ElasticNet 在 60M 和 1B 的绝对 Loss 平均偏差仍为 $+1.502982$ 与 $+2.612864$ 。它没有学习规模响应；P2/P3 若采用其配比差分，必须继续将 $(_p)$ 和尺度转移作为情景。10B/70B 的估算标签差值均约 -0.005 RMSE，且不是实测，不能推翻或支持跨规模胜出。新的独立配方与多规模训练实验仍是最终确认的关键证据。

1B 的 13 个验证域中，8 个 RMSE 降低、5 个退步；其中 `arxiv`、`freelaw`、`pubmed_central`、`github` 的回顾性配对区间不跨零。60M 和 1B 的绝对 Loss 存在明显共同偏移，所以 P2 只使用相对参考配方的 Δ_p ，并以 λ_p 标注跨规模幅度。Q_A 没有已完成的人工盲评，选择等权代理是透明、解释性和定义敏感性之间的取舍，不写成“质量被验证”。

6.9 为什么不直接回归 17 个比例

对闭合配比， $\sum_{i=1}^{17} p_i = 1$ 。若同时设置截距和全部比例作为线性特征，设计矩阵必然秩亏；任意一个域系数改变都必须通过其他域的改变实现，单个“保持其余 16 域不变”的导数不在可行域内。即使删去一列使线性回归可计算，回归系数也会随删去的参考域改变，无法把系数当作某域的独立价值。ALR 使用 $\log [(p_i + \epsilon)/(p_r + \epsilon)]$ ，使比例只通过相对份额进入模型；零替换量由训练折确定，防止测试数据影响坐标变换。

二阶 ALR 特征共有 16 个一次项、16 个平方项和 120 个交互项，共 152 维。512 个训练配方拟合 13 个响应，若为每个响应分别选择特征，将使相关的验证域估计更不稳定。MultiTask ElasticNet 的 $\ell_{2,1}$ 惩罚在 13 个响应上共享特征选择，同时用二次惩罚收缩相关特征；选定解激活 136/152 个特征。因此“稀疏”是相对无惩罚二阶模型的联合收缩，不宜描述为只依赖少数领域。二阶交互提供局部曲率，却不表示观察到真实训练中的领域协同因果效应。

6.10 质量代理选择的解释性代价

把 22 项信号直接等权会让语义接近、相关较高的字段重复计数。四组等权先在教育价值、可读性、洁净度和结构内聚合，再在概念组间等权，故主分数的定义可逐项复查。CRITIC 用离散度及相关性调整权重，鲁棒聚合抑制极端组分，PCA 和熵权则检验定义变化是否引起排序漂移；这些方法均不能在没有人工标签的情况下自行建立“真实质量”标尺。

质量代理的无监督敏感性（A1 七来源域，与四组等权基线比较）

代理方式	域排序 Spearman	样本平均绝对分差	解释
四组等权	1.0000	0.0000	主报告口径
CRITIC	0.9286	0.0279	离散度/相关性加权
鲁棒聚合	0.9643	0.0323	压低极端组分
冲突惩罚	1.0000	0.0368	排序未变，绝对值变化

表中相关和分差均来自 `problem1/outputs/tables/quality_model_comparison.csv`。PCA 一因子域排序与主代理的 Spearman 为 0.25，提示单轴压缩会改变问题定义；它不是等权方案的外部有效性检验。因而本文把 Q_A 用于相对筛选和冲突定位，把人工盲评与同配比异质量训练留作后续校准，而不据 Q_A 推断训练 Loss 的确定改善。

6.11 选定模型的总体收益与逐域损失

选择配比模型时，主指标是 A6/A7 的 1M pooled RMSE，训练内嵌套 OOF、60M/1B、排序及逐域稳定性是共同约束。ElasticNet 对 Ridge 的 1M 配对 RMSE 改善为 0.015834，条件 95% 区间为 [0.010465,0.021037]；1B 改善为 0.013406，区间为 [0.007823,0.018795]。这些区间对既定配方行重抽样，不能重新定义为模型开发之前封存的外部置信区间。60M 的改善区间跨零，故只报告数值接近。CLR 样条在 1M 的 RMSE 为 0.208173，优于选定模型，但 1B 的 2.735706 高于 Ridge 的 2.702111；其单尺度收益不足以替代跨问所需的配比接口。

对 1B 的逐域结果，8 域下降与 5 域上升同时成立，不能用 pooled 指标掩盖个别验证域的退步。模型若用于某一指定领域，应先查看该域在附录 B 的独立指标和区间；本文后续只把 13 域汇总的相对配比差作为条件输入。

6.12 领域替代效应的定义与稳定性

配比约束使“增加某领域 1 个百分点”必须同时说明从哪一领域转出。对参考配方 p_0 ，本文固定从 `pile_cc` 转出 0.01 到目标域，在其他域不变且仍保持非负时，计算选定模型的预测差。该差分是局部方向量，不是一个领域的全局回归系数，更不是大规模重新训练后的真实收益。若参考配方接近边界，某些 1 个百分点的转移不可行；超出 A4/A5 配比支持的候选也只可作外推情景。

最终 ElasticNet 与冻结 Ridge 在 16 个局部方向中的 15 个符号一致，唯一不一致的 `pubmed_abstracts` 效应本身极小；固定规格在 40 次训练行 bootstrap 中，只有 9/16 方向达到至少 90% 同号率。因此适合报告模型对候选配方的相对排序和总体 Loss 差，而不应把每一个方向的符号写成稳健定论。交互项同样如此：二阶特征允许在支持域内弯曲，但数据尚未给出同时通过 bootstrap、模型规格与多重比较检查的稳定互补对。正文使用“预测关联”和“条件差分”，附录保留逐方向结果供复核。

6.13 1B 的逐域配对结果

正值表示选定 ElasticNet 相对 Ridge 的 RMSE 改善；负值是退步。该表将 pooled 指标的权衡展开到 13 个验证域，区间来自既定配方行的回顾性重抽样。

验证域	Ridge-选定 RMSE	95% 下界	95% 上界
arxiv	-0.0235736	-0.0389024	-0.00836261
freelaw	-0.0188046	-0.0286011	-0.00909795
pubmed_central	-0.0209048	-0.0317043	-0.0102115
wikipedia_en	0.00815754	-7.42074e-05	0.0155968
dm_mathematics	0.0649035	0.0395418	0.0914425
github	-0.0404319	-0.0567867	-0.0249766
stackexchange	-0.00901633	-0.0233442	0.00522449
gutenberg_pg_19	0.0305054	0.0231756	0.037592
pile_cc	0.0163742	0.0121644	0.0199262
ubuntu_irc	0.101454	0.0767367	0.124401
hackernews	0.0273364	0.0197519	0.034896
pubmed_abstracts	0.00896982	-0.000479014	0.0181491
uspto_backgrounds	0.0061729	-0.00213305	0.0141584

7 问题二：质量条件标度律

本节记录 B 组数据结构和公式推导。较早技术记录中的问题一旧配比模型描述仅作研发背景；正文的配比接口以选定链为准。

7.1 B 组数据与来源口径

编号来自 `数据说明2.pdf`；行数、范围和字段由 `problem2/outputs/tables/data_audit_b.csv` 与原始文件核对。B3 是目录中 8 个轨迹文件，合计 4,000 行。B11/B12 是辅助元数据，不是新增 Loss 实验。

编号	文件（均在 <code>real_attachments/B_scaling_laws/</code> ）	性质与行数	关键字段、范围	本项目用途
B1	<code>pythia_training_log_existing.csv</code>	真实 Pythia 轨迹，1,176	<code>run_id,N_params_B,D_tokens_B,val_loss</code> : 8 个参数规模: $N=0.070542-11.965825$ 、 $D=0.134-299.893$ 、 $Loss\ 2.0933-4.7388$	唯一经典 N-D 主拟合；按模型规模分组检验
B2	<code>cerebras_training_log.csv</code>	半合成 Cerebras 轨迹，1,029	$N=0.111-13$ ， $D=14-2,050$ ， $Loss\ 2.8354-6.4979$	族外 raw 偏移和校准研究
B3	<code>training_trajectories/pythia*_trajectory.csv</code>	8×500 插值点	<code>N_params_B,D_tokens_B,val_loss,step,interpolated</code>	同族曲线插值核查，非独立真实验证

编号	文 件 （ 均 在 real_attachments/B_sca ling_laws/）	性质与行数	关键字段、范围	本项目用途
B4	scaling_baseline.csv	跨模型族汇总，57	family,N_params_B,D_to kens_B,val_loss,is_con verged; $N = 0.07 - 72$	跨族 raw 比较; Loss 口 径未证实一致
B5	published_scaling_data .csv	文献尺度汇总，44	family,N_params_B,D_to kens_B,val_loss,source ,is_converged; $N = 0.125 - 540$	文 献 尺 度 raw 比 较 ; Loss 口径未证实一致
B6	supplementary_NQ_exper iment.csv	半合成 $N - D - Q$ ，360	N_params_B,D_tokens_B, Q_score,val_loss; $Q = 0.1 - 1$	Q 候选的唯一拟合集
B7	supplementary_NQ_exper iment_expanded.csv	半合成扩展，450	同 B6; 含 B6 全部 360 个键	去重后的 90 个新点作开 发验证
B8	supplementary_NQ_exper iment_large.csv	半合成大网格，1,704	另 有 data_type: $N = 0.07 - 700$, $D = 5 -$ $2,000$, $Q = 0.05 - 1$, Loss 下界 0.5	对 B7 去重后 1,480 点 作机制诊断; 不得用于 Q 参数拟合
B9	supplementary_large_mo dels.csv	大模型元数据，132	model_name,N_params_B, D_tokens_B,FLOPs,...; $N = 100 - 10,000$	与 B10 按名字、 N,D 关 联; 非 Loss 标签
B10	supplementary_large_ba seLINE.csv	估算 Loss，128	family,N_params_B,D_to kens_B,val_loss; $N = 100 - 10,000$	100B+ 诊断性外推; 不是 实测验证
B11	open_model_family_meta data.csv	模型来源/文件元数据，18	family,model_repo,..., error	辅助来源清点: 未入主模 型
B12	pythia_checkpoint_inde x.csv	Pythia 检查点索引，1,386	model_repo,model_size, step,branch,commit	辅助核对检查点: 未作为 拟合标签

B1 的 1,176 行属于同一 Pythia family 的多个时间检查点，不是 1,176 次相互独立训练。B2 的“Cerebras”名称不改变其附件中的半合成性质。B6 - B8 是按真实规律校准的补充机制表，能检验本题公式在该机制下能否重现数据，不能推出真实世界质量改善的因果效应。B9 比 B10 多 4 行，实际外推代码通过一对一关联保留 128 个 B10 对应条目。

7.2 经典 $N - D$ 基线与估计

经典式 $L_{ND} = E + AN^{-\alpha} + BD^{-\beta}$ 与 Chinchilla 一类加性幂律模型一致，允许分别识别参数与 token 的边际衰减。V1 run_problem2.py:fit_classic 对 B1 做 SciPy least_squares，直接估计正参数，界为 $E \in [0,4]$ 、 $A,B \in [10^{-5},100]$ 、 $\alpha,\beta \in [0.005,2]$ ；四组初值择残差平方和最小者。它不是“对全部参数取对数再优化”。V2 models.py:fit_nd 用同样有界残差拟合候选，并保存 nd_fit_comparison.csv。V1 classical_scaling_params.csv 的多初值最大差均约 10^{-11} ，说明同一 B1 目标上的数值收敛稳定。

7.3 主项参数与数学意义

problem2/outputs/tables/classical_scaling_params.csv 与 V2 nd_fit_comparison.csv 一致：

$$E = 1.689797563, \quad A = 0.353980321, \quad \alpha = 0.339976582, \quad B = 1.240305584, \quad \beta = 0.279878129.$$
$$L_{ND} = 1.689797563 + 0.353980321N^{-0.339976582} + 1.240305584D^{-0.279878129}.$$

N 增加一倍时，参数损失项乘 $2^{-0.339977} \approx 0.790$ ； D 增加一倍时，数据损失项乘 $2^{-0.279878} \approx 0.824$ 。这说的是对应损失分量而非总 Loss 同比例下降；总 Loss 中还有 E 和其余项。系数的物理尺度依赖 B 单位和同一评测 Loss 口径。

7.4 留参数组验证

B1 是同一 run 多检查点轨迹，随机拆行会让训练集直接看到验证点前后的同轨迹点，误差过于乐观。V1 run_problem2.py:classical 按 8 个 N_params_B 留一整组，逐次在其余 7 组拟合，并与训练均值 M0 比较，结果存于 classical_scaling_cv.csv。V2 run_v2.py:nd_experiments 对全部 $N - D$ 候选重复留 N 分组；还取最小若干 N 训练预测更大 N ，以及每一规模的早期 D 训练预测后期 D ，详见 nd_group_cv.csv、nd_scale_extrapolation.csv。B1 classic 分组汇总 RMSE 0.00015118，小到大 N 截断汇总 RMSE 0.00014298。留模型能防止直接检查点泄漏，仍只检验 Pythia 同族规律，不代表全新模型族的泛化误差。

7.5 跨来源原始误差

下表来自 problem2/outputs/tables/external_validation_metrics.csv，bias 统一定义为预测减观测。B2/B4/B5 在 V2 多候选研究中已被查看，应称“开发性跨源比较”，不再称全新封存测试。

数据	n	RMSE	MAE	Bias	Spearman	解释
B2 raw	1,029	1.243085	1.178442	-1.178442	0.788102	半合成族外轨迹，绝对水平显著偏低估
B3 插值	4,000	0.003821	0.002893	-0.001968	0.999990	同族插值，形状核查，不独立
B4 raw	57	0.292667	0.227263	-0.221009	0.982982	跨族排序较好，绝对口径仍偏
B5 raw	44	0.197595	0.170722	-0.020570	0.958808	文献尺度排序较好，评测口径未统一

B2 逐 run 见 b2_by_model_metrics.csv，V2 diagnostics/b2_raw_residuals.csv 与 source_residual_trends.csv 显示观测减预测同 $\log D$ 强相关，相关系数约 -0.977 ，故不只是固定截距。B4/B5 的 Spearman 高说明排序趋势仍可用；RMSE 和 bias 不应被排名指标遮蔽。V1 报告中的 B4/B5 全量数据上事后截距校准只是描述性数值，不能充当独立验证。

在固定 N 、 D 时，质量项的效果可能随模型容量改变：更大模型可利用不同的信息，也可能对噪声更敏感。该机制只是提出 $Q_{B \times N}$ 候选的理论动机，现有 B6/B7 半合成数据只支持条件预测比较，不能证明上述因果过程。候选按加性质量、 $Q_{B \times N}$ 、 $Q_{B \times N \times D}$ 与有效 Token 形式比较。

7.6 质量项候选比较

V2 真正的实现位于 `problem2_v2/models.py:predict_q,fit_q`；5 个 N - D 参数固定为 B1 拟合，所有 Q 候选只在 B6 用有界非线性最小二乘拟合。下式的 L_{ND} 均为第 6 节经典项。

代码名	实际公式	新增参数
additive	$L_{ND} + G(1 - Q)^K$	2
effective_power	$E + AN^{-\alpha} + B(DQ^\gamma)^{-\beta}$	1
effective_exp	$E + AN^{-\alpha} + B[De^{\gamma(Q-1)}]^{-\beta}$	1
saturating	$L_{ND} + G\{e^{-tQ} - e^{-t}\}/(1 - e^{-t})$; $t \rightarrow 0$ 时取 $G(1 - Q)$	2
quality_data ($Q \times D$)	$L_{ND} + G(1 - Q)^K (D/100)^{-\eta_D}$	3
quality_model ($Q \times N$)	$L_{ND} + G(1 - Q)^K N^{-\eta_N}$	3

有效 token 模型让较低 Q 缩小有效 D ； $Q \times D / Q \times N$ 则让质量惩罚幅度随数据量或规模变化。结果出自 `quality_model_scorecard.csv`，B7/B8 均为前述去重新点；BIC 是 B6 质量拟合的指标，不能与 B1 的 BIC 相加。

表 4 问题二候选标度律比较

模型	参数数	B6 RMSE	B6 留 N RMSE	B7_new RMSE	B8_new RMSE	BIC
additive	2	0.076068	0.081440	0.059515	1.392571	-1843.04
effective_power	1	0.116973	0.119565	0.105570	1.402068	-1539.10
effective_exp	1	0.102931	0.106377	0.079602	1.384888	-1631.17
saturating	2	0.076070	0.081405	0.059521	1.392598	-1843.02
quality_data	3	0.075085	0.080596	0.058900	1.393510	-1846.52
quality_model	3	0.051804	0.052346	0.042127	1.341755	-2113.75

`quality_fit_comparison.csv` 给每种参数和条件数；饱和模型的 $t \approx 3.5 \times 10^{-10}$ 、Jacobian 条件数为无穷，事实上退化为加性直线，不能声称发现明确饱和。 $Q \times D$ 的 $\eta_D = 0.041233$ ，改善较小。

7.7 简约模型的选择

V2 预设选择逻辑在 `run_v2.py:report`：候选相对 additive 的 B7_new RMSE 至少改善 5%，B8 误差不变差，B6 BIC 至少下降 6；B8 只作为冲突排查，不能凭其较低误差选型。 $Q \times N$ 达到门槛，参数来自 `quality_fit_comparison.csv`：

$$G_C = 0.3568073634, \quad \kappa_C = 0.9915434612, \quad \eta_N = 0.1620729235.$$

它让 B6 留 N RMSE 从 0.081440 $\rightarrow$ 0.052346，B7_new 从 0.059515 $\rightarrow$ 0.042127（改善约 29.2%），BIC 从 -1843.04 $\rightarrow$ -2113.75，B8_new 仅从 1.392571 $\rightarrow$ 1.341755，仍极差。200 次按 B6 的 N 组重采样得到 η_N 的 95% 分位区间 [0.148572, 0.200805]，`quality_model_intervals.csv` 可查。这支持“在 B6 半合成机制下，质量惩罚与模型规模关联”，不能写成真实训练中质量收益的因果律。

7.8 异机制冲突检验

V2 `diagnostics/b6_b8_exact_overlap_conflicts.csv` 有 160 个完全相同的 (N, D, Q) ，但 Loss 不同，B8 减 B6 的均值为 -1.15361； $Q=1$ 时约 -0.0125， $Q=0.1$ 时约 -2.1583，差异并非固定源截距。`quality_monotonicity.csv` 显示在可比较的同 N, D 组内，“ Q 越高 Loss 越低”的比例：B6 为 100%，B7 全网格为 100%，B8_new 为 0%。B8 反向并有 0.5 的 Loss 下界。V1 对 B8_new 的观测减预测残差均值约 -1.1517，`b8_residual_trends.csv` 给残差与 Q 的相关 $r = 0.9744$ ，与 $\log N$ 的相关仅 $r = -0.0126$ 。这同时表明模型在 B8 上拟合差，以及 B6 与 B8 的数据机制/质量语义本身冲突。任何保持“更高 Q 一定更低 Loss”的单一单调律都不能同时无误解释两者；不能偷偷用 B8 标签重拟合后把它说成独立成功验证。




图 4 质量条件标度律与候选模型比较

7.9 N-D 复杂候选复核

V2 models.py:predict_nd,fit_nd 与 run_v2.py:nd_experiments 测试 classic、交互项 $HN^{-\alpha}D^{-\beta}$ 、compute-ratio $E+K(6ND)^{-\epsilon}(N/D)^{\epsilon t}$ 、平滑 broken-N $E+AN^{-\alpha}[1+(N/N_c)^2]^{-\delta/2}+BD^{-\beta}$ ，以及经典律的 Huber、soft-L1、relative、log 残差目标。所有 N-D 参数只用 B1 拟合。

候选	参数数	B1 留组 RMSE	小到大 N RMSE	BIC	B2/B4/B5 RMSE	raw
classic	5	0.00015118	0.00014298	-20729.31	1.24308 0.29267 0.19760	/ / /
interaction	6	0.00015232	0.00014560	-20722.62	1.24308 0.29267 0.19760	/ / /
compute_ratio	4	0.097604	0.124717	-5993.22	1.31283 0.31712 0.18174	/ / /
broken_N	7	0.00015174	0.00012952	-20720.85	1.24308 0.29267 0.19757	/ / /
classic_huber	5	0.00015118	0.00014298	-20729.31	1.24308 0.29267 0.19760	/ / /
classic_soft_l1	5	0.00015118	0.00014298	-20729.31	1.24308 0.29267 0.19760	/ / /
classic_relative	5	0.00014935	0.00012837	-20721.05	1.24307 0.29266 0.19760	/ / /
classic_log	5	0.00015012	0.00013370	-20728.02	1.24308 0.29266 0.19760	/ / /

Broken-N 的 B1 小到大外推有微小改善，但 BIC 较差、跨源几乎没改进，拟合 $\delta = -0.000711$ 接近零，Jacobian 条件数约 3.12×10^{10} ，阈值 N_c 弱识别；broken_threshold_profile.csv 固定多个阈值时 δ 仍近零。因此保留 classic 主干。relative/log 改变了训练目标，虽有局部 RMSE 变化，也未稳定解决来源偏移。 $C \approx 6ND$ 在 compute-ratio 中只是重参数化约束，没有提供新观测。

7.10 来源校准与零样本区分

B1→B2 的 raw 全量 bias 为 -1.178442，N-D 结构换成复杂候选后几乎不变。V2 run_v2.py:nd_experiments 把 B2 按每个 run_id 的早期 D、B4/B5 按 family 排序取约 20% 作目标来源有标签校准集，其余约 80% 为 holdout；source_calibration_holdout.csv 记录 raw、截距、仿射、log D 修正。截距可解释来源特定的有效 E，仿射形式是

$$L_s^{cal}(N, D) = a_s + c_s L_{ND}(N, D),$$

其中 a_s 调整损失起点、 c_s 调整该来源的 Loss 尺度。Model B 将仿射形式预先固定，不对 Q 或 p 项做同样缩放，因为 B2/B4/B5 没有联合测量可识别它们。

来源	校准/holdout 行数	同一 holdout raw RMSE	截距 RMSE	仿射 RMSE	log D RMSE
B2	203 / 826	1.033103	0.788919	0.695515	0.367362
B4	12 / 45	0.248204	0.221161	0.091646	0.161231
B5	9 / 35	0.188934	0.218046	0.161882	0.189887

B2 的 $\log D$ 修正局部更好，但不在 B4/B5 同时占优；其系数也需要该源标签。校准集内部 L00 自适应形式在 B5 误选截距，使 holdout 0.218045，劣于 raw，因此最终 Model B 不是自适应形式选择。Model B 的 B2 仿射参数 $a = -0.240309, c = 1.861322$ ，B4 $a = -0.815261, c = 1.484678$ ，B5 $a = -0.716658, c = 1.343569$ ，见 model_B_source_calibrated.joblib。全量 raw 的 B2 RMSE 1.243085 与后 80% raw 的 1.033103 样本不同，不能直接相减当成校准收益。有目标来源 20% 标签之后的改善不等于零样本泛化成功；多种校准方案已在同一数据上比较，结果属于描述性条件 holdout。

7.11 选定模型与配比接口

本节以最终复赛表为依据，说明 $N-D$ 与 Q_B 子模型的选择、来源标签校准和配比接口。

7.12 N-D 最终复赛

比较 classic: $E+A N^{-\alpha}+B D^{-\beta}$ 、interaction: classic+ $H N^{-\alpha} D^{-\beta}$ 和 broken-N。仅 B1 的 1176 行用于最小二乘参数估计；按完整 N 组逐一留出，且将较小 N 或早期 D 作为训练集单独测试外推。所有模型对 B2/B4/B5 均不重新拟合，评价是原始零样本预测。

model	B1_training_rmse	B1_group_cv_rmse	B2_raw_rmse	B4_raw_rmse	B5_raw_rmse	B1_bic	jacobian_condition
classic	0.00014650	0.00015118	1.24308	0.29267	0.19760	-20729.31	1.14e+03
interaction	0.00014647	0.00015232	1.24308	0.29267	0.19760	-20722.62	1.56e+03
broken_N	0.00014614	0.00015512	1.24308	0.29267	0.19757	-20720.85	3.12e+10

交互与 broken-N 的训练误差略低，但 B1 留 N RMSE 从 0.00015118 增至 0.00015232、0.00015512。broken-N 条件数 3.12e+10，在半数较小 N 训练的高 N 测试上明显失稳。故保留 classic；B2/B4/B5 原始 RMSE 1.2431/0.2927/0.1976，外部来源偏移是主要误差，不可用 B1 近乎零的训练误差掩盖。

7.13 质量项最终复赛

固定重拟合的 classic N-D 参数，在 B6 360 行上分别拟合加性 Q 、 $D_{\text{eff}}=D Q^{\gamma}$ 、 $Q \times N$ 、 $Q \times D$ 与低秩 $Q \times N \times D$ 。B6 按 N 留组；B7 相对 B6 去重后的 90 个输入点评价。B8 的标签没有参与任何正常方向 Q 候选拟合和选择。

model	B6_training_rmse	B6_leave_N_rmse	B7_new_rmse	B6_bic	jacobian_condition
additive	0.07607	0.08144	0.05952	-1843.04	8.82e+01
effective_tokens	0.11697	0.11957	0.10557	-1539.10	1.00e+00
Q_by_N	0.05180	0.05235	0.04213	-2113.75	9.99e+01
Q_by_D	0.07508	0.08060	0.05890	-1846.52	8.84e+01
Q_by_ND	0.05036	0.05106	0.04117	-2128.20	9.99e+01

$Q \times N \times D$ 在 B6 留 N 和 B7 新点分别比 $Q \times N$ 改善 2.46% 和 2.28%，但均低于预注册 5% 门槛。按 B7 的 N 组配对自举，RMSE 改善 95% 区间 $[-0.00111, 0.00262]$ 覆盖 0。新增 D 指数在 B6 组自举区间 $[0.0259, 0.0546]$ ，表明可作机制敏感性；组外收益不够稳健，主模型继续采用 $Q \times N$ 。

7.14 选定函数与单位

本轮从原始 B1/B6 重新估计的模型为：

$$L = 1.6897975629 + 0.3539803207 N^{-0.3399765819} + 1.2403055836 D^{-0.2798781285} + 0.3568073584 (1 - Q_B)^{0.9915433891} N^{-0.1620729110} + \lambda_p \Delta_p$$

N、D 都按十亿计。 $Q_B=1$ 时 Q 项为零，回到 N-D 律。 Q_B 的训练机制限于 B6/B7； Δ_p 由最终问题一模型预测相对相同参考配方的中心化 Loss 差。预测代码 predict_final.py 从 selection.json 读取参数，对 N、D、 Q 做输入范围检查。

7.15 来源应用边界

source_conditional_holdout.csv 使用每条 B2 轨迹或 B4/B5 家族早期 20% 已知 Loss 拟合来源截距、仿射或 $\log D$ 残差修正，再评估后期 80%。此协议消耗目标来源标签，不能放入前述零样本分数中，也不能自动把来源修正乘到 Q/p 项。多种形式在本轮均已查看，以下最优形式只是描述性，不宣称全新封存验证：B2=source_logD_20pct，RMSE 0.3674，B4=source_affine_20pct，RMSE 0.0916，B5=source_affine_20pct，RMSE 0.1619。

source	protocol	calibration_rows	holdout_rows	rmse
B2	raw	203	826	1.03310
B2	source_intercept_20pct	203	826	0.78892
B2	source_affine_20pct	203	826	0.69552
B2	source_logD_20pct	203	826	0.36736
B4	raw	12	45	0.24820
B4	source_intercept_20pct	12	45	0.22116
B4	source_affine_20pct	12	45	0.09165
B4	source_logD_20pct	12	45	0.16123
B5	raw	9	35	0.18893
B5	source_intercept_20pct	9	35	0.21805
B5	source_affine_20pct	9	35	0.16188

source	protocol	calibration_rows	holdout_rows	rmse
B5	source_logD_20pct	9	35	0.18989

完全不使用 B5 标签估计时，从 B2+B4 平均来源偏移迁移到 B5 的 RMSE 为 1.0696，而原始 classic 为 0.1976。来源修正不能作为通用无标签规律。

7.16 B8 的不同生成机制

B6 与 B8 有 160 个相同 (N,D,Q_B) 输入，B8-B6 Loss 平均 -1.15361。在各 (N,D) 网格中，Q 增加而 Loss 降低的比例：B6=100%，B7=100%，B8 新点=0%。同点不同标签及相反斜率证明不能把 B8 作为同一确定性质量律的验证通过。B8 包含 calibrated 与 extrapolated 类型；这些不是独立现实大模型实验。

7.17 与问题一、三的接口

最终接口采用 $L(N,D,Q_B,p)=L_{NDQ}+\lambda p \Delta p(p)$ 。当前 $\lambda p=1$ 是定义参考情景，不是根据 B 数据估出的跨规模参数。 λp 场景的 λp 的幂衰减、带底值和上下界探索敏感性，所有 identified=false。B 数据不含联合 (N,D,Q,p) 多规模 Loss 标签，所以不能从问题一的单尺度配方响应或其他论文推断 $\lambda p(N)$ 。尽管 Ye 等，ICLR 2025 研究了数据混合规律，其数据不能代替本题独立锚点。

问题一质量指数 Q_A 与 B6/B7 的 Q_B 不同，缺乏同一训练样本的成对测量与共同 Loss 锚点。故无法识别 $Q_A \rightarrow Q_B$ 映射，问题三若使用 Q_B 必须明示情景或另取标注。若问题一的最终配方模型发生变化，应重算 Δp ，并顺序重跑问题三与问题四受影响的結果。

7.18 条件项的边际解释与误差来源

选定函数的质量惩罚为 $G(1-Q_B)^K N^{-\eta_N}$ 。在给定 N、D 时，质量改善的局部边际收益是 $GK(1-Q_B)^{K-1} N^{-\eta_N}$ ；它随 N 变化，故同一质量分差不能在所有参数规模上换算为相同 Loss 差。在 $Q_B=1$ 的边界，条件项归零；这只代表拟合函数的规范化，并不意味着真实语料达到无噪声极限。B1 的 0.000151 留组误差与 B2 的 1.2431 原始误差相差数个数量级，来源测量口径不能用组内精度代替。

若对目标来源用早期 Loss 标签估计截距或仿射修正，所得留后段误差已经消耗该来源标签，评价性质是“来源条件校准”，不是零样本外部验证。该校准也不能无证据地施加到 Q_B 或配比差分上。

7.19 历史候选与情景结构的可复核计算

本附录展开配比跨尺度传递、外推层级、历史能力分解和条件预测的开发记录。主文的数值结论以选定链表格为准；开发记录中的阶段性候选仅用于方法比较。

配比效应和跨尺度可信度

问题二保存的最终 P1 V2 在 1M/60M/1B 的中心化斜率分别为 0.822/0.609/0.182，用的是已查看过的测试标签，仅为回顾性证据，不是 $\lambda p(N)$ 的估计。1B 配方均值排序在 V2 下弱于 V1；旧 V1 斜率另存 $p_scale_v1_evidence_audit.csv$ 。本问以 1M ($N_B=.001$) 为情景归一化点，比较常数 1、幂次衰减 $\rho=.1/.2$ 、以及 $\rho=.15$ 且地板 .25。固定 λ 枚举 0、.25、.5、.75、1、1.25、1.5。模型可分意味着 $\lambda>0$ 时 p 候选排序不变，N-D-Q 不变，收益按 λ 伸缩； $\lambda=0$ 时所有 p 并列。

策略	$\lambda=1$ 的 $\Delta Loss$	变换空间支持等级	kNN5	Mahalanobis	PCA 残差
P0_reference	0	in-support	2.1628	2.095	0.4821
P1_observed_support	-0.50224	in-support	2.0865	3.5722	1.2429
P2_continuous_support	-0.56865	in-support	2.1326	4.2217	1.0701
P3_loose_simplex	-1.1951	extrapolative	3.2774	21.688	2.0077

支持度采用与问题一一致的 ALR 变换，训练空间标准化后计算 5 近邻距离、保留 95% 方差的 PCA 坐标收缩协方差 Mahalanobis 距离和 PCA 重构残差。各指标阈值来自 512 条训练样本 95/99 分位数；in-support/near-support/extrapolative 是经验诊断，不是外部验证。P2 连续候选仅在最优观测配比的 12 个邻近训练配比凸组合内搜索，并须通过全部 95% 支持检验。P1 实际观测配比仍为论文主候选；Loose 只作数学诊断。

证据等级与结论

三种质量成本是同等级题设情景：中高预算 Q 饱和是跨情景共识；低预算质量投资高度依赖成本假设。联合参数 bootstrap 区间很窄，主要反映 B1 在固定经典公式下近乎确定性的轨迹，不能解释为现实模型参数或跨数据源误差也同样小。它不覆盖成本函数、Q0、C7 元数据与 B8 外部来源失配。跨场景共识区间才用于展示这些结构性假设的变化。

长上下文使同样 N-D 的成本增加，主情景下反而让相对便宜的 Q 更早值得投资：指数成本的起投点从 2048 tokens 的约 3.90×10^{18} 降到 32768 tokens 的约 2.21×10^{18} ；这是给定成本结构与 Model C 的替代效应，不是通用规律。对数成本的起投与饱和同点，表示最优 Q 出现离散跳跃，不能把它解释为渐进质量投资阶段。

10^{24} 下 E1 的 N 与 D 同时碰到 $3 \times$ 上界，全部 36 个场景在此角点共享同一个最优解，所以 minimax regret=0；这是一种边界驱动的退化结果，不是高预算风险已被消除。软罚解在 $\omega=.01-1$ 下仍达到 $N \approx 60-75B$ 、 $D \approx 1.9-2.4T$ ，与 E1 的 $N \approx 35.9B$ 、 $D \approx 0.90T$ 相距明显，软罚并未独立支持 $3 \times$ 推荐。E1 缓和强外推，却不能升级为实证解；预算仍有大量未使用。

论文主文应采用 V2 的跨情景共识与 E0/E1/E2 三层对照；单一 $\lambda p=1$ 收益、精确结构点及 E2 高预算 Loss 只作为条件情景结果。

复现与文件映射

从仓库根目录运行 `python problem3_v2/run_v2.py. methods.py` 只读引入 V1 的数学成本与预测函数，新增精确活动集、硬封顶求解和 KKT 诊断。`mixture_evidence.py` 重算配比训练支持和 λ 情景。`run_v2.py` 负责联合 bootstrap、E0/E1/E2、minimax regret、图表与报告。全部 V2 文件保存在 `problem3_v2/outputs`；V1 的 SHA-256 前后清单写入 `v1_integrity.json`。

所有以 $3\times$ 、 ρ 、floor、场景等标记的数值都是敏感性假设。`joint_bootstrap_parameters.csv` 可审计每个模型八参数及其原 B6 replicate；`joint_bootstrap_optima.csv` 逐次保存四档优化结果。`robust_scenario_optima.csv` 保存后悔值的逐场景基准，保证 minimax regret 可独立复算。

模型适用范围

优点：真实解析逐任务 JSON，C2 进行反核对，C4 仅接受高置信直接匹配，所有路径可复现，情景和条件区间分开。限制：榜单直接历史仅九个月；严格实体匹配率约1%；季度末开放样本只有2个；C6 高可比仅7行；Loss 尺度未跨模型族校准；Q/p 跨尺度未识别；未来12/24个月无法回溯。残差时间趋势包含选择、工程和评测适配，不能称严格因果效应。

结论

能稳健写入论文的是数据口径、逐任务验证、桥接误差、算力长期增长及无法验证长期预测的限制。2.15/4.69 分贡献与未来点预测只能列为明确标注的小样本敏感性情景，不能作为确定性的历史份额或未来承诺。

对 38 个交付问题的逐项回答

1. 六项 Benchmark 0-100 等权平均；预测用 logit 尺度。
2. C8 成功 1860 个模型目录；3 个目录未达到预设条件、4 个损坏 JSON 已记录。
3. Pearson 0.952, Spearman 0.953。
4. Open-W1=C4 明确开放权重+原发布方严格匹配+六项完整；W2再要求明确许可标签。
5. 45 个独立模型。
6. pretrained 32; chat/finetuned 10; 其他 3。
7. Submission Date; Release Date 作匹配与敏感性。
8. 严格直接匹配 46/4576=1.01%; C2 候选 447/4576=9.77%，含继承关联。
9. C4 年度 compute 倍率：长期 $3.67\times$ ，2023-24 近期 $7.26\times$ 。
10. 未发现稳健放缓：piecewise BIC -4.22，单斜率 BIC -7.12。
11. 严格主样本首末季度 p95 数值差 -2.80 分；末季 $n=2<5$ ，不能判定趋势方向。
12. 结构模型隐含算力贡献 2.15 分，仅探索性。
13. 结构模型隐含剩余时间贡献 4.69 分，仅探索性。
14. 模型内比例 31.5%/68.5%，但模型与观测方向冲突，不可作稳健份额。
15. 最近12/24月无法估计；可观测近两季的模型项为算力 -13.63、时间 2.92 分。
16. 不同：chat/finetuned 有10个严格开放模型、reported compute 更少，无法单独识别贡献。
17. C6 可比性加权、单调有界 logistic。
18. GroupKFold 的 C6 主桥接 RMSE 11.86 分。
19. 不一致：Loss=2.0 的 weighted/high-only/all-unweighted 映射 20.38/5.92/21.72 分。
20. 六维与逐任务相关高，但弱项相关 0.918，个别排名偏差见 `c8_vs_leaderboard.csv`。
21. 2025-01-31
22. 2026-01-31
23. 2027-01-31
24. 延续算力：12月 50.81、24月 71.13 分。
25. 中度放缓：12月 43.37、24月 57.51 分。
26. 强放缓：12月 39.73、24月 50.09 分。
27. 各情景50/80/95%条件区间详见 `frontier_forecast_12m_24m.csv`；未经12/24月覆盖率校准。
28. 12/24月无有效滚动回溯；3月有 2 折，原趋势 RMSE 7.96 分。持平短期基线见 `short_term_baseline_comparison.csv`，合格目标 $n\geq 5$ 仅 1 个。
29. P1/P2-V2/P3-V2 在中度放缓、E1/P0 下12/24月均 20.94 分，受资源上限钳制。
30. 中度放缓 12/24 月数据驱动减机理：22.43/36.58 分。
31. C6 Loss 尺度与后训练能力不完全可比，且 E1 达 N/D 上限；数据趋势超出九个月观测。
32. 本窗口的剩余时间项约等效 $1.96\times$ compute；不稳定，仅敏感性。
33. 榜单六项均无人达90分；未观测到明显 ceiling，logit 用于防止未来越界。
34. C8 p95 增量最大任务族为 math (+26.8 个百分点)；样本构成会变化。
35. 可作主结论：数据来源审计、C8逐任务代表性、桥接误差、C4长期算力趋势、不可回溯的限制。
36. 规模/技术百分比、C2继承匹配前沿、12/24月分数、P1配比收益和E2均只能作敏感性。
37. 直接榜单九个月且严格匹配稀疏；最后季度仅2个开放模型，长期预测无回溯。
38. 验证中未通过的是12月/24月直接回溯与分解方向一致性；具体数量见 `verification_results.json`。

7.20 质量和规模相互作用的可解释范围

选定质量项可写成 $h(Q_B, N) = G(1 - Q_B)^K N^{\eta_N}$ 。这给出两个不同问题：一是固定规模时把 Q_B 从一个值提高到另一个值，条件 Loss 变化为两点 h 之差；二是固定 Q_B 时增加 N ，质量惩罚随 N^{η_N} 缩小。数据支持的是 B6 留 N 和 B7 新

点的预测精度，不能从指数符号反推模型“识别了质量的全部机制”。如果高质量数据同时改变 Token 多样性、训练长度或评估集分布，现有单变量 Q_B 函数无法分离这些途径。

候选比较必须保留复杂模型的局部优势。 $Q \times N \times D$ 在 B6 留 N 的 RMSE 约 0.05106，略小于 $Q \times N$ 的 0.05235；B7 新点约 0.04117，也略小于 0.04213。然而 B7 按 N 组配对 bootstrap 的进一步改善区间覆盖零，新增自由度在组外没有稳定收益。采用 $Q \times N$ 是预测收益、参数数量与来源相容性之间的保守选择，不是宣称 $Q \times N \times D$ 在每一列分数上均劣。

跨来源原始误差的解释也需要区分“目标函数不适用”和“参数完全无效”。B1 的同族轨迹和 B2/B4/B5 可能有不同的验证 Token、损失底数、归一化方法和训练协议。未经目标来源标签校准的 raw RMSE 暴露口径偏移，不能凭这些误差单独判定 N、D 的局部单调关系无效。反过来，用目标来源前 20% 标签校准后留下的后 80% 误差，也不能再称零样本泛化。两类评价同时呈现，让评委区分结构可迁移性与量尺可迁移性。

7.21 配比项和质量项为何不能直接合并估计

A 组记录有完整 17 域配比，却没有与 B1/B6 同口径、同时变化的 N、D、 Q_B 、Loss 网格；B6 的 Q_B 不是 A 组规则代理 Q_A 的重标。因而联合拟合 $L(N, D, Q, p)$ 会把来源差、配比效应和质量效应混在一起。本文采取模块化方式：先固定 B1 的 N-D 主项与 B6 的质量条件项，再以 $\Delta_p(p) = f_A(p) - f_A(p_0)$ 接入相对配比响应。中心化移除了 P1 的绝对 Loss 截距，使 P2 的 B1 底数不被 P1 的 1M 量尺直接污染。

这一构造仍留下 λ_p 。设 $\lambda_p=0$ 是“不使用配比收益”的保守情景， $\lambda_p=1$ 是同幅度参考情景，其他常数或随 N 衰减/增长的形式只用于敏感性。没有多规模同配比再训练时，任何 $\lambda_p(N)$ 的形状都不能被现有表格识别。问题三因此要把它列为情景输入，不能把选定配比自动当作大规模训练的已证收益。

7.22 质量提升与参数增加的条件等价

题目要求回答“质量提升 0.1 等价于多少参数”。对固定 D、配比和起点 (N, Q_B) ，先求提升质量后的目标 $L(N, D, Q_B + 0.1, p)$ ，再找 N_{eq} 使原质量下 $L(N_{eq}, D, Q_B, p)$ 等于该目标。由于 E、数据项和固定配比差分在等式两侧抵消，需要解的只是 $AN_{eq}^{-\alpha} + G(1 - Q_B)^K N_{eq}^{-\eta_N} = AN^{-\alpha} + G(1 - Q_B - 0.1)^K N^{-\eta_N}$ 。对选定 Model C 可用一维求根得到精确条件倍数 N_{eq}/N ；这不是把局部导数机械乘以 0.1。

在既有 quality_equivalence_by_model.csv 的 $D = 300B, Q_B: 0.6 \rightarrow 0.7$ 情景中，1B 起点对应 $N_{eq} = 1.2951B$ ，7B 起点对应 9.9002B，即约 1.4143 倍。70B 起点的条件解为 112.9627B，但 70B 与其等价值都远超 B1 最大实测 N，不能作为现实工程换算。若改用早期加性 Q 模型、改变 $Q_A \rightarrow Q_B$ 映射或重新校准 Loss 口径，倍数会变化。故等价值是固定模型、质量量尺和起点的条件量，不是“质量比参数重要”的无条件定律。

7.23 弹性与有限变化的区别

模型对 N、D、 Q_B 的局部 Loss 弹性可统一定义为 $\epsilon_x^{(L)} = (x/L)\partial L/\partial x$ ；若关心可约损失，则把分母换为 $L - E$ 。两个定义回答不同问题，尤其当 Loss 接近不可约项 E 时，后者的绝对值可比前者大很多。给定 Q_B 和配比，N 的导数包含参数主项与质量交互项，D 的导数只来自数据主项； Q_B 的导数只在 B 组质量量尺内有意义。把弹性乘以 1% 是局部小变化近似，不能代替“质量增加 0.1”或“参数翻倍”的有限差分。附录 C 保存早期 Model A 的数值弹性，正文不把旧模型的数值搬到最终 Model C。

若考虑每单位 FLOPs 的边际收益，不能只比较 $|\partial L/\partial N|$ 与 $|\partial L/\partial Q_B|$ ，因为两项的成本导数不同。规划内点满足带成本梯度的 KKT 比值条件；达到 $Q_B=1$ 、N/D 上界或预算不绑定时，则由对应活动约束决定。由此把问题二的局部替代关系与问题三的实际预算选择接起来，也说明单看质量与参数的等价倍数不足以决定投资方向。

8 问题三：算力约束下资源配置优化

本节列出成本假设、外推边界、共同可行策略与数值检查；主文的条件方案与此处表格使用相同参数和单位。

8.1 目标、变量、约束与可行域

给定预算 C、基线质量 Q_0 和候选配比 p，优化变量为 N、D、 Q_B ；若配比也优化，则需限制在 A4/A5 支持域。目标为最小化问题二选定的 $L(N, D, Q_B, p)$ ，约束为训练、质量处理、上下文三项成本之和不超过 C，及各情景的 N、D、 Q_B 上下界。若 N、 Q_B 、p 固定，L 对 D 严格递减，最优 D 是预算允许值与硬上界的较小者。由此把三维规划化为 N、 Q_B 的二维有界搜索；D 的预算解析值由数值求根独立核对。

$$\min_{N, D, Q_B, p} L(N, D, Q_B, p) \quad \text{s.t.} \quad C_{tot}(N, D, Q_B) \leq C, N \in [N, \bar{N}], D \in [D, \bar{D}], Q_B \in [Q_0, 1], p \in \mathcal{P}.$$

这一形式把目标、可行域、活动边界与配比支持条件分开；E0/E1/E2 只改变上界而不改变损失参数。

8.2 三项成本与最优性条件

下表对 $3 \times \text{minimax}$ 政策核算。前三项和中心使用率对应指数成本、 $Q_0 = 0.6$ 、4096 上下文；最坏使用率对应 12 种结构情景中的最大成本。因此共同可行并不意味着每个情景都花满预算。

预算 FLOPs	中心训练	中心质量	中心注意力	中心总使用	最坏结构总使用
10^{19}	30.34%	16.21%	4.14%	50.69%	100.00%
10^{22}	43.58%	6.48%	5.95%	56.01%	100.00%
10^{24}	19.38%	0.33%	2.65%	22.35%	40.99%

10^{24} 的 $3 \times$ 政策在中心情景只用约 22.35% 预算，在最坏结构情景也只用约 40.99%。闲置由 N/D 外推上限驱动，不能通过在上限外继续增大 N/D 来伪装为已验证收益。free 单情景名义解的 KKT 残差如下； $Q=1$ 时采用单侧互补条件：

预算 FLOPs	free 名义 KKT 相对误差	Q 互补
10 ¹⁹	7.34e-08	通过
10 ²²	1.72e-08	通过
10 ²⁴	3.46e-08	通过

minimax/CVaR 目标和硬上限交界可不平滑；其八个局部可行方向最大改善量为 1.596e-13，这是数值局部检查，不是完整 KKT 证书。全部 75 个政策对 12 种结构情景的可行率为 100%；成本独立重算误差最大 4e-12。

8.3 质量投资的活动集转折

对 $Q^* > Q_0 + 10^{-4}$ 与 $Q^* \geq 1 - 10^{-4}$ 的首次预算，先扫描括区间，再在 $\log_{10}$ 预算上二分到容差 2×10^{-6} dex。端点 cusp 用全局候选和边界搜索保护。若在扫描区间外才触发，明确报告 below_scan/above_scan，不伪造数值。精度是给定 ϵ 与模型的数值精度，不是统计置信区间。

成本模型	事件	FLOPs	状态
exponential	start	3.7024e+18	crossing
exponential	saturation	1.377e+20	crossing
power	start	1.2912e+19	crossing
power	saturation	7.215e+19	crossing
logarithmic	start	2.0036e+18	crossing
logarithmic	saturation	2.0036e+18	crossing

成本模型	C7 上下文	事件	FLOPs
exponential	2048	start	3.9021e+18
exponential	2048	saturation	1.4428e+20
exponential	4096	start	3.7024e+18
exponential	4096	saturation	1.377e+20
exponential	32768	start	2.205e+18
exponential	32768	saturation	8.6692e+19
power	2048	start	1.3606e+19
power	2048	saturation	7.5467e+19
power	4096	start	1.2912e+19
power	4096	saturation	7.215e+19
power	32768	start	7.7042e+18
power	32768	saturation	4.6206e+19
logarithmic	2048	start	2.1026e+18
logarithmic	2048	saturation	2.1026e+18
logarithmic	4096	start	2.0036e+18
logarithmic	4096	saturation	2.0036e+18
logarithmic	32768	start	1.2433e+18
logarithmic	32768	saturation	1.2433e+18

另外对 $\log N$ 、 $\log D$ 、 Q 、质量预算份额做 0/1/2 折点的连续分段线性拟合，以 BIC 选择并计入折点位置参数。结果见 structural_break_analysis.csv。分段折点描述轨迹斜率，不应与 Q 活跃约束转移混为同一物理临界点。




图 5 不同预算下的质量投入结构点

8.4 解析消元与数值误差

自由解的预算使用率误差最大 $2.22\text{e-}16$ 。100 个随机点对 $D = C/[(6 + \eta L) 10^{18} N + 10^9 (g(Q) - g(Q_0))]$ 与 Brent 数值根比较, 最大相对误差 $3.26\text{e-}16$ 。自由解及联合 bootstrap 内点/边界 KKT 中位相对误差 $6.16\text{e-}08$, 最大 $4.24\text{e-}06$; Q 端点采用单侧互补条件。若极端 bootstrap 样本 KKT 异常, 应查看 `kkt_diagnostics.csv`, 不可掩盖。

当 $Q = 1$ 且质量成本份额趋小, 令 $K = C/[(6 + \eta L) 10^{18}]$, 有 $D = K/N$ 。一阶条件给 $N^* = [(\alpha A) / (\beta B) K^\beta]^{1/(\alpha + \beta)}$, 故 $e_N = \beta / (\alpha + \beta) = 0.451522$ 、 $e_D = \alpha / (\alpha + \beta) = 0.548478$ 。D/N 的理论预算指数为 $0.096956 > 0$, 解释高预算 D/N 上升。在 10^{24} 数值局部弹性为 $N=0.444625$ 、 $D=0.561340$; 质量成本仍非零, 所以仅渐近靠近理论, 详见 `high_budget_elasticity.csv`。

8.5 三档预算与证据边界

下表是指数质量成本、 $Q_0 = 0.6$ 、4096 上下文的单情景最优; E0 限在 B1 实测 N/D 范围, E1 上界扩大 3 倍, E2 自由外推。E1 是敏感性边界, 不是实测可信区间。

预算 FLOPs	等级	N (B)	D (B)	Q	Loss	预算使用
10^{19}	E0: 实测域	0.31138	3.9555	0.72412	3.1804	100.00%
10^{19}	E1: 3× 边界	0.31138	3.9555	0.72412	3.1804	100.00%
10^{19}	E2: 自由外推	0.31138	3.9555	0.72412	3.1804	100.00%
10^{22}	E0: 实测域	5.4332	245.59	1	2.1547	100.00%
10^{22}	E1: 3× 边界	5.4332	245.59	1	2.1547	100.00%
10^{22}	E2: 自由外推	5.4332	245.59	1	2.1547	100.00%
10^{24}	E0: 实测域	11.966	299.89	1	2.0934	2.56%
10^{24}	E1: 3× 边界	35.897	899.68	1	1.9794	22.35%
10^{24}	E2: 自由外推	39.562	3657	1	1.916	100.00%

10^{19} 与 10^{22} 的三层基本重合; 10^{24} 时 E0/E1 都碰到 N、D 硬上限且闲置大量预算, E2 使用全部预算但 D 达约 3657B, 超出 B1 观测上限约 12.2 倍。故“Loss 更低”不能直接视为更可信的生产方案。

表 5 典型预算下的单情景最优配置 (指数质量成本, $Q_0=0.6$, $L_{ctx}=4096$; N、D 单位为 B)

预算 FLOPs	等级	N	D	Q_B	Loss	预算使用率
10^{19}	E0/E1/E2	0.311	3.956	0.724	3.1804	100%
10^{22}	E0/E1/E2	5.433	245.59	1	2.1547	100%
10^{24}	E0 观测域	11.966	299.89	1	2.0934	2.56%
10^{24}	E1 三倍上界	35.897	899.68	1	1.9794	22.35%
10^{24}	E2 自由外推	39.562	3657.0	1	1.9160	100%

10^{24} 档的 E1 剩余算力来自 N、D 上界同时激活, 不能解读为“最优训练应闲置算力”。E2 的更低 Loss 对应 D 超出 B1 观测上界约 12.2 倍。




图 6 E0、E1、E2 证据边界下的条件配置

8.6 上界剖面与稳健决策

E0 把 N,D 限于 B1 观测范围; E1 限于 B1 上界 3 倍 (明确是敏感性边界); E2 是自由 Scaling Law。硬约束下 D 在每个 N,Q 取预算允许与 D 上界的较小值, 避免 V1 对封顶问题使用惩罚近似。软 log 越界平方罚项另做 $\omega=.01$ 至 1 的诊断, 不作为主模型。


FLOPs	层级	N_B	D_B	Q_B	Loss	已用预算
1e+19	E0_empirical	0.31138	3.9555	0.72412	3.1804	100.0%
1e+19	E1_moderate_3x	0.31138	3.9555	0.72412	3.1804	100.0%
1e+19	E2_free_scaling	0.31138	3.9555	0.72412	3.1804	100.0%
1e+22	E0_empirical	5.4332	245.59	1	2.1547	100.0%
1e+22	E1_moderate_3x	5.4332	245.59	1	2.1547	100.0%

FLOPs	层级	N_B	D_B	Q_B	Loss	已用预算
1e+22	E2_free_scaling	5.4332	245.59	1	2.1547	100.0%
1e+24	E0_empirical	11.966	299.89	1	2.0934	2.6%
1e+24	E1_moderate_3x	35.897	899.68	1	1.9794	22.4%
1e+24	E2_free_scaling	39.562	3657	1	1.916	100.0%

3× 上限并非实测可信域；将两维上限同时放宽至 B1 最大值的 1/2/3/5/10 倍，另与自由解比较。10²⁴ FLOPs 的剖面如下（完整结果在 cap_sensitivity_profile.csv）：

上限倍数	N_B	D_B	Loss	已用预算
1	11.966	299.89	2.0934	2.6%
2	23.932	599.79	2.0171	10.0%
3	35.897	899.68	1.9794	22.4%
5	59.829	1499.5	1.9381	61.7%
10	48.361	2998.9	1.9164	100.0%
free	39.562	3657	1.916	100.0%

3× 到 5× 的 Loss 仍明显变化，所以 E1 只是一种明确的条件情景，不是唯一可推荐规模。10²² FLOPs 下这些上限均未起作用。



稳健决策采用 E1 3× B1 上界。代表场景为 3 个真实联合 bootstrap 向量 × 三种成本 × 两个 Q0 × 两个 C7 长度，共 36 个场景。固定配置要求对全部场景可行，故共同 $Q \geq .8$ ；D 由各场景允许值的最小值决定。每场景后悔值为其 Loss 与同场景 E1 最优 Loss 的差，目标最小化最大后悔值。 λ_p 对固定 p 策略的 N-D-Q 决策可分，因此其不确定性在配比结论中单列，不虚构为 N-D-Q 风险。对 nominal 和 empirical 配置另外报告共同可行域修复后的公平比较。

FLOPs	配置	N_B	D_B	Q_B	nominal Loss	最大场景后悔
1e+19	robust_minimax	0.30994	1.6315	0.81871	3.3778	0.33408
1e+19	nominal_moderate_repaired	0.31138	1.6377	0.8	3.3839	0.34026
1e+19	empirical_repaired	0.31138	1.6377	0.8	3.3839	0.34026
1e+19	nominal_moderate_raw	0.31138	3.9555	0.72412	3.1804	infeasible policy
1e+22	robust_minimax	4.1129	176.6	1	2.2002	0.056129
1e+22	nominal_moderate_repaired	5.4332	136.62	1	2.2021	0.058086
1e+22	empirical_repaired	5.4332	136.62	1	2.2021	0.058086
1e+22	nominal_moderate_raw	5.4332	245.59	1	2.1547	infeasible policy
1e+24	robust_minimax	35.897	899.68	1	1.9794	0
1e+24	nominal_moderate_repaired	35.897	899.68	1	1.9794	0
1e+24	empirical_repaired	11.966	299.89	1	2.0934	0.11398
1e+24	nominal_moderate_raw	35.897	899.68	1	1.9794	infeasible policy

这是一套明确的稳健决策规则，不等于数据证明 3× 边界合理。若未修复的 nominal 配置在其他成本/上下文情景不可行，其 raw regret 不计算。

8.7 决策规则与保留理由

冻结 Champion 为 P3 V2 的 $3\times B1$ 上界内 minimax regret。本轮对同一 Model C 和成本公式重算 $1\times$ 、 $2\times$ 、 $3\times$ 、 $5\times$ 、free 五个上限，及名义共同可行最优、minimax、平衡均值 regret、CVaR90 regret、最差情景 Loss 五个规则。训练为 3 个完整联合 bootstrap 参数向量乘 12 个结构情景；留出为不同的 12 个参数向量乘同样结构情景。留出参数来自同一 B1/B6 原始数据重采样，不属于独立外部验证。情景平均只描述平衡设计，不代表现实期望。

每个情景 s 的后悔值为 $R_s(x) = L_s(x) - \min_{y \in \mathcal{F}_s} L_s(y)$ 。域内 regret 用该上限的 oracle，跨上限比较统一使用 free oracle。本轮预先规定，替代 Champion 需共同可行、留出改善至少 0.005 Loss 且 5%、配对参数簇 bootstrap 正改善比例超过 90%，并且不增加实际 N/D 外推。复赛审计 decision_audit.csv 中没有候选同时通过。

8.8 高预算上界敏感性

下表使用 10^{24} FLOPs、同一留出情景和同一 free oracle。共同名义 Loss 是 minimax 政策在中心模型上的 Loss；单情景 Loss 是独立指数 $4096/Q_0 = 0.6$ 的 raw nominal 最优，后者在 $5\times$ /free 下只有一半结构情景可行，不能当共同政策比较。

上限	共同 N (B)	共同 D (B)	共同名义 Loss	单情景 Loss	自由均值 regret	自由最大 regret	最坏成本率
1x	11.966	299.89	2.0934	2.0934	0.16749	0.17998	4.7%
2x	23.932	599.79	2.0171	2.0171	0.091208	0.10367	18.3%
3x	35.897	899.68	1.9794	1.9794	0.053511	0.06597	41.0%
5x	52.727	1499.5	1.9419	1.9381	0.016051	0.02851	100.0%
free	30.02	2618.8	1.9382	1.916	0.012312	0.024769	100.0%

在 $3\times$ 内，36 个训练情景的解共享同一个角点，使域内 regret 为 0；留出情景也如此。但相同 $3\times$ 政策对 free oracle 的留出均值 regret 是 0.05351102。 $5\times$ 与 free 降低此条件后悔值，却分别把 D 推到 B1 上限的 5 倍与约 8.732 倍。没有独立数据支持这样的外推上限，故报告 Pareto 剖面，不给唯一高预算规模。 $3\times$ minimax 仅保留为清楚标注条件的展示政策。

8.9 后悔值与共同可行解

原 V2 把单情景名义解截入共同可行域后直接比较。截入后没有重新优化 N/Q， 10^{19} 下修复名义方案的留出平均 regret 约 0.172389。本轮直接在共同可行域重优化名义目标，得到更公平的对照：

预算 FLOPs	规则	留出平均域内 regret	CVaR90 regret	最大 regret
10^{19}	Minimax regret	0.166278679	0.3223818835	0.3358900219
10^{19}	Nominal, shared feasible	0.1662788303	0.3223819626	0.3358901743
10^{19}	Balanced mean regret	0.1662802523	0.3223829703	0.3358916025
10^{19}	CVaR90 regret	0.1662802975	0.3223830056	0.3358916478
10^{19}	Worst-case loss	0.166278679	0.3223818835	0.3358900219
10^{22}	Minimax regret	0.02704512885	0.0552343727	0.05613047497
10^{22}	Nominal, shared feasible	0.02704512505	0.05523436855	0.0561304727
10^{22}	Balanced mean regret	0.02704512609	0.05523436976	0.05613047303
10^{22}	CVaR90 regret	0.02704512581	0.05523436944	0.05613047288
10^{22}	Worst-case loss	0.02704512521	0.05523436876	0.05613047266

10^{19} 下公平名义方案与 minimax 的平均 regret 仅差约 1.5×10^{-7} ； 10^{22} 下差约 3.8×10^{-9} 。mean、CVaR90、最差 Loss 规则也只出现极小数值差异。此证据不支持换用更复杂风险准则，也不支持宣称 minimax 对公平名义优化具有实质性能优势。保留 minimax 是既有可解释条件政策的延续；简化为共同可行名义方案亦几乎等价。

8.10 配比收益与支持域

在固定 $Q_0 = 0.6$ 、4096 上下文时，质量投资起点定义为 $Q^* > Q_0 + 10^{-4}$ ，饱和点为 $Q^* \geq 1 - 10^{-4}$ 。扫描后在 $\log_{10} C$ 上二分。阈值是给定模型的数值结果，不是统计置信区间：

质量成本	起投 FLOPs	饱和 FLOPs
exponential	3.70242e+18	1.377e+20
power	1.29122e+19	7.21496e+19
logarithmic	2.00357e+18	2.00357e+18

对数成本的起投与饱和点，表示当前模型下的离散跳跃，不应绘成连续过渡。不同质量成本情景的阈值差异也说明，不宜给不附条件的统一起投预算。

配比项在固定 $\lambda_p > 0$ 且可加可分时不改变 N-D-Q 最优。冻结 P1/P2 桥接下，观测配比候选预测 $\Delta_p = -0.497303$ 、在训练支持域内；宽松 simplex 候选预测 $\Delta_p = -0.893035$ ，却属外推。跨尺度 $\lambda_p(N)$ 未被独立识别，因此不能把 1M 配比收益直接外推到高预算，也不能在此复赛中用配比项“抵消”规模决策风险。若最终 P1 或 P2 桥接改变，需重算本问及 P4 下游。

8.11 KKT 边界与预算剩余的解释

对固定配比，把成本约束写为 $h(N, D, Q_B) = C_{tot} - C \leq 0$ ，并为 N、D、Q_B 的上下界分别引入非负乘子。内点处一阶条件是 $\nabla L + \mu \nabla h = 0$ ，同时满足 $\mu h = 0$ 。在 $Q_B = Q_0$ 或 1 时应检查单侧导数与互补条件；硬上界的乘子非零时，预算乘子可以为零，因此 E0/E1 的高预算解允许预算未用尽。现有核查表分别报告自由解的预算残差、解析 D 与数值求根差及内点/边界 KKT 残差。

配置的不确定性分成两类。第一类是给定成本与上界时参数重抽样引起的条件波动；第二类是改变质量成本形式、基线 Q_0 、上下文长度或 E0/E1/E2 上界造成的结构差异。后者不是前者的置信区间。高预算下 E1 的三倍上界同时约束 N 和 D，结构差异主导结论，故应同时报告预算使用率和相对自由解的后悔值。

8.12 成本场景与算法补充审计

以下记录对应问题三早期基线及其后续外推检查。表格用于展示成本结构和算法实现过程；正文的条件解与证据分级仍以选定链为准。

算力成本与单位

$$N_{\text{raw}} = 10^9 N_B, D_{\text{raw}} = 10^9 D_B.$$
$$C_{\text{train}} = 6 \times 10^{18} N_B D_B, \quad C_Q = 10^9 D_B [g(Q_B) - g(Q_0)]_+, \quad C_{\text{attn}} = 2 \times 10^{14} N_B D_B L_{\text{ctx}}.$$

指数、幂、对数三种 g 分别为 $10^7 e^{6Q}$ 、 $5 \times 10^9 Q^4$ 、 $2 \times 10^9 \ln(1 + 10Q)$ 。三者均完整求解；指数函数仅作为叙述主情景，因为其递增边际成本给出内点 Q ，便于展示起投和饱和两类机制，并无实证证据证明它比另外两者更真实。主情景 $Q_0 = 0.6$ 、C7 中位上下文 4096； $Q_0 = 0.2/0.8$ 及另两成本为敏感性情景。B6 没有唯一可识别的 Q_0 。

$$C_{\text{attn}}/C_{\text{train}} = \eta L_{\text{ctx}}/6, \quad L_{\text{ctx}}^{\text{crit}} = 6/(2 \times 10^{-4}) = 30000.$$

C7 共 45 行，缺失 0；中位 4096，最小 2048、最大 131072。实际值 2048, 4096, 8192, 32768, 131072；低于 30000 的 33 行，高于的 12 行；临界点两侧最近值 8192 与 32768。131072 是单个长尾值，不作为主情景。短/中/长选 2048/4096/32768。

优化与数值方法

在 $C_{\text{total}} \leq C$ 、 $Q_0 \leq Q_B \leq 1$ 、 p 为 simplex 下最小化 Model C。第一阶段固定 $p = p_{\text{ref}}$ ；将 D 用绑定预算解析消元，优化 $\log N_B$ 与有界 Q_B 。三档主预算均运行 differential evolution、SLSQP 多初值及 Q 边界一维搜索。密集轨迹为 10^{18} 至 10^{25} 的 71 个对数点。 p 单独求解，因为成本与 N-D-Q 主损失对 p 可分。

三档预算主结果

FLOPs	N_B	D_B	Q_B	Loss	训练	质量	attention
1e+19	0.3114	3.956	0.7241	3.18	73.9%	16.0%	10.1%
1e+22	5.433	245.6	1	2.155	80.1%	9.0%	10.9%
1e+24	39.56	3657	1	1.916	86.8%	1.3%	11.9%

图见 outputs/figures/resource_allocation_low_medium_high.png。占比是成本除预算，不是 token 数量占比。

三种质量成本

g	FLOPs	N_B	D_B	Q_B	Loss
exponential	1e+19	0.3114	3.956	0.7241	3.18
exponential	1e+22	5.433	245.6	1	2.155
exponential	1e+24	39.56	3657	1	1.916
power	1e+19	0.271	5.412	0.6	3.193
power	1e+22	5.528	237.8	1	2.156
power	1e+24	39.67	3638	1	1.916
logarithmic	1e+19	0.3214	3.23	1	3.104
logarithmic	1e+22	5.018	284.7	1	2.149
logarithmic	1e+24	39.1	3738	1	1.916

三函数是题定的成本情景，不是数据拟合。其差异只能解释为成本假设敏感性。

上下文敏感性与结构性转移

短、中、长上下文均逐预算重新优化，完整结果见 context_sensitivity.csv。上下文超 30000 后，attention 成本超过基础训练成本。结构性转移定义为 Q 下界退出、 Q 上界到达，或相邻 log 预算步的份额 L1 变化超过 0.05/0.10。它们是可复现的离散网格判据，不是物理相变。

判据	首次触发 FLOPs
Q_start	3.981e+18
Q_saturation	1.585e+20
share_jump_tau_0.05	5.012e+18
share_jump_tau_0.10	not observed

N、D 的预算弹性与 D/N 见 `optimal_nd_ratio.csv`。若主情景没有 Q 起投点或饱和点，按未观察到报告，不能人为指定。Model C 中 Q 罚项随 N 增加而减弱，因此 Q 不必单调随预算上升。

配比优化与 KKT

P0 使用均匀参考配比；P1 在 512 条问题一实际训练配比中选择预测最优者，这是严格训练支持域方案；Loose 用 softmax 连续优化，仅作数学外推诊断。

策略	相对 Loss 改变	超出局部支持	最大单域占比
P0_reference	0	False	0.05882
P1_observed_support	-0.5022	False	0.363
P1_loose_simplex	-1.195	False	0.4442

p 不消耗额外 FLOPs，因而同一 $\lambda_p > 0$ 下，N-D-Q 最优值不随 λ_p 改变；绝对 Loss 改变量与 λ_p 成比例。`lambda_p_sensitivity.csv` 枚举 0.5、0.75、1、1.25、1.5。内点 KKT 要求三项 $-\partial L / \partial x / \partial C / \partial x$ 相等；Q 在上下界时改用不等式。逐预算数值见 `marginal_loss_reduction_per_flop.csv`。

不确定性、外推与推荐

90 个情景抽取 Q0、C7 上下文、成本函数，并按问题二边际 bootstrap 区间近似抽取 G、 κ 、 η_N 。边际独立抽样不保留参数相关性，不是严格联合置信区间。结果见 `optimization_uncertainty.csv`。外推档位按 B1 区间的三倍外侧标为 strong；主理论方案强外推预算： $1e+24$ 。`empirical_range_allocations.csv` 提供 N、D 限在 B1 内的稳健对照；预算可能不绑定，表示数据支持范围内没有理由强行用完大预算。数学最优是无限制 Scaling Law 解；稳健推荐应优先引用实证范围方案，并明确其模型配比与 Q0 仍有假设。

成本和外推补充图

图 E1 展示上下文长度对质量投入预算的影响；图 E2 显示共同参数重抽样的配置分布；图 E3 刻画配比候选与训练支持域的关系。这些图均对应给定成本和抽样规则。




图 E1 上下文长度与质量投入转折




图 E2 联合参数重抽样下的配置




图 E3 配比候选的训练支持域

8.13 高预算极限下的规模与数据分配

当 $Q_B=1$ 且质量处理成本在总预算中的占比趋小时，设 $K = C / (6 + 2 \times 10^{-4} L_{ctx}) 10^{18}$ ，则成本边界近似为 $ND = K$ ，可写 $D = K/N$ 。将它代入 $N-D$ 主项后，一阶条件平衡了规模侧与数据侧的边际 Loss 减少： $\alpha AN^{-\alpha-1} = \beta BK^{-\beta} N^{\beta-1}$ 。因此 $N^* = [(\alpha A)/(\beta B) K^\beta]^{1/(\alpha+\beta)}$ ，数据量由 $D^* = K/N^*$ 给出。相应预算弹性为 $d \log N^* / d \log C = \beta/(\alpha + \beta)$ ， $d \log D^* / d \log C = \alpha/(\alpha + \beta)$ 。

这个渐近关系解释为什么高预算自由解倾向同时增大 N 与 D ，也解释在本模型参数下 D/N 可随预算上升。它是忽略质量成本份额、未激活 N/D 硬上界时的模型内极限；E0/E1 的 10^{24} 解碰到双上界，不能套用自由解弹性。正文把解析关系放在数值结果之后，是为了让“更大模型或更多数据”的趋势与具体上界敏感性有清楚区分。

8.14 决策可用性的两层检验

第一层是求解正确性：预算公式单位一致、 D 消元与数值求根吻合、自由解预算约束绑定、KKT 残差处于既定容差内。第二层是证据适用性：候选 N/D 是否在 B1 支持域内，所选 Q_B 的成本函数与基线是否有依据，配比是否仍靠近 A4/A5 训练支持域，以及 Loss 是否需要跨来源校准。第一层通过只能说明“给定模型下的最优点对了”，不能自动使第二层通过。

在 10^{24} 档位，E0 的 Loss 2.0934、E1 的 1.9794、E2 的 1.9160 是上界放松后的条件 Pareto 剖面。E1 相对 E0 改善，但仍有 77.65% 的算力未用；E2 用满预算，却把 D 推至约 3657B。报告三者及其预算率比仅报告 E2 的最小 Loss 更能回答实际资源配置：是否值得进入更高外推等级取决于团队对额外训练证据的要求，而不是优化器的数值误差。

8.15 稳健目标与共同可行域

单情景最优只须满足自身成本、上下文和 Q_0 约束；稳健政策必须在全部备选结构情景中可行。若把单情景指数成本下的 raw nominal 解直接拿来比较所有成本，部分情景会超预算，此时“后悔值”没有可行政策含义。本文先将候选修到共同可行域，再按每个情景的 oracle 定义 regret，并在跨上界比较时使用同一 free oracle。 10^{24} 、三倍上界的共同可行 minimax 政策相对 free oracle 的留出平均 regret 为 0.053511，而不是零；同上界内的零后悔仅表示这些情景共享一个边界角点。

已有复赛对共同名义、minimax、平均、CVaR90 和最差 Loss 规则作同样的留出比较。低、中预算中几种规则的差别很小，因此不能声称更复杂风险准则带来明显增益。保留 minimax 是为了清楚呈现“最坏情景相对损失”的决策目标，同时报告公平名义对照。若未来有真实质量处理成本和预算分布，可以按实际风险偏好重新定准则；现有三种成本函数没有经验概率权重。

8.16 联合参数传播与条件区间

问题二的 200 组 B6 聚类 bootstrap 原样用于审计。由于未保存 B1 的联合 bootstrap，V2 对 B1 的 8 个 N 簇重采样并拟合五个经典参数；对 B6 的 9 个 N 簇采用问题二相同随机种子重放抽样，再在对应 B1 参数下拟合 G 、 κ 、 η 。这样保留 B6 三参数内部依赖，并传播 B1 参数到质量拟合的条件影响。B1/B6 属不同来源，其跨源协方差未识别；这些分位数是参数 bootstrap 条件下的优化分布，不是完整现实置信区间。

FLOPs	变量	5%	25%	中位	75%	95%
1e+19	N_B	0.30792	0.30975	0.31157	0.31484	0.32912
1e+19	D_B	3.6573	3.8925	3.9511	3.9806	4.0154
1e+19	Q_B	0.72033	0.72264	0.7247	0.72797	0.74132
1e+19	loss	3.1754	3.1787	3.181	3.1834	3.1893
1e+20	N_B	0.93294	0.94509	0.95556	0.96642	1.0025
1e+20	D_B	9.5195	10.417	10.695	10.951	11.264
1e+20	Q_B	0.94354	0.95332	0.96161	0.97043	1
1e+20	loss	2.7008	2.7019	2.7026	2.7032	2.7036
1e+22	N_B	5.4306	5.432	5.4332	5.4341	5.4352
1e+22	D_B	245.51	245.55	245.59	245.64	245.69
1e+22	Q_B	1	1	1	1	1
1e+22	loss	2.1547	2.1547	2.1547	2.1547	2.1547
1e+24	N_B	39.516	39.544	39.563	39.575	39.591
1e+24	D_B	3654.3	3655.8	3656.9	3658.6	3661.2

FLOPs	变量	5%	25%	中位	75%	95%
1e+24	Q_B	1	1	1	1	1
1e+24	loss	1.916	1.916	1.916	1.916	1.9161

FLOPs	P(Q=1)	P(Q=Q0)	P(N>B1max)	P(D>B1max)	P(两维>3×B1max)
1e+19	0.0%	0.0%	0.0%	0.0%	0.0%
1e+20	10.5%	0.0%	0.0%	0.0%	0.0%
1e+22	100.0%	0.0%	0.0%	0.0%	0.0%
1e+24	100.0%	0.0%	100.0%	100.0%	100.0%

跨成本、Q0、上下文、联合参数的平衡情景集合是敏感性集合，不赋予自然发生概率：

FLOPs	N 中位 [5%, 95%]	D 中位 [5%, 95%]	Q 中位 [5%, 95%]	Q=1 情景比率
1e+19	0.27958 [0.18348, 0.44276]	3.3101 [1.7801, 6.2466]	0.8 [0.6, 1]	33.0%
1e+22	5.2944 [3.7776, 5.7062]	244.44 [180.55, 294.02]	1 [1, 1]	100.0%
1e+24	39.564 [29.641, 40.838]	3680.4 [2627.7, 3866.9]	1 [1, 1]	100.0%

9 问题四：能力前沿分析

本节展开模型匹配、逐任务汇总、能力桥接与季度前沿定义。预测数值以选定链和主文的冻结原点为准。

9.1 样本筛选与时间口径

主口径 Open-W1: C4 Open model weights?=Yes 且经过严格发布方核对、六基准完整。得到 45 个独立模型，pretrained 32、chat/finetuned 10、其他 3。Open-W2 另要求存在可明确归为 permissive 或 research-only 的许可证标签，共 27 个模型；法律许可仍须逐条核验。主时间为 Submission Date。开放主样本截止日/预测原点为 2025-01-31，12/24 月目标日为 2026-01-31 / 2027-01-31。严格匹配记录的提交日期减发布日期中位数为 49 天；日期差值分布见 open_source_filter_audit.csv。C4 未来模型绝不进入历史。

9.2 Benchmark 能力指数

扫描 1958 个 JSON、1863 个目录，成功解析 1860 个模型，3 个目录不可用，4 个损坏文件记录于 c8_parse_failures.csv。逐任务使用 40 个叶任务、74344 个模型-任务分数；固定每类可比 metric，逐任务 percentile 后均值/第25百分位，覆盖至少半数任务及三个任务族才合格。与 C1 六维均值 Pearson=0.952、Spearman=0.953；弱项指标 Pearson=0.918。汇总有较高代表性，个别模型仍有排序偏差。六任务族前沿从首至末季度变化（百分点）：math +26.8，mmlu +4.2，ifeval +3.5，gpqa +2.0，musr +1.0，bbh +0.0。这些来自不断变化的提交模型集合，不是同一模型的纵向改进。

9.3 六基准汇总

主指标 $S=(\text{IFEval}+\text{BBH}+\text{MATH Lvl 5}+\text{GPQA}+\text{MUSR}+\text{MMLU-PRO})/6$ ，0-100 分。六项均完整，无均值填补。稳健 z 分与 PCA 第一成是敏感性，主分与 PCA 得分相关 0.983。预测使用 $\text{logit}(S/100)$ 保证边界。

9.4 Loss—能力桥接

C6 高可比 7 行、中可比 68 行。比较线性、logistic、isotonic；按模型族 GroupKFold，主桥接用高权重1、中权重 0.35 的有界单调 logistic，组外 RMSE=11.86 分。权重是敏感性设定，非经验真值。在 Loss=2.0 处，weighted/high-only/all-unweighted 的 logistic 映射分别为 20.38/5.92/21.72 分。C5、各可比性层和六个单项模型均见桥接表；high-only 仅一个主要系列，无法可靠外推。桥接误差较大，机理预测不能解释为精确分数。

9.5 严格季度前沿

开放权重六维完整模型的季度 p95：2024Q2=33.02(n=22)，2024Q3=38.12(n=16)，2024Q4=32.38(n=5)，2025Q1=30.22(n=2)。同时给出 all/W2、pretrained/chat 的 p90、p95、Top3、Top1，见 quarterly_frontier.csv。最后一季只有 2 个严格匹配模型，前沿受样本选择影响很大。C2 继承匹配的宽口径敏感性共 420 个模型，首末季 p95 从 31.48 到 41.49；方向与严格口径相反，但其实体对应不能逐项确认。

frontier_definition_sensitivity.csv 将单季最低样本数预设为 5/10，并列 1-3 季完整滚动窗口及相同 W1 截止日期的 C2 宽口径。严格单季 $n \geq 5$ 只比较至 2024Q4，相对首季变化 -0.63 分； $n \geq 10$ 只比较至 2024Q3，变化 +5.10 分；三季窗口 2024Q4→2025Q1 为 +2.21 分。统一截止日期的 C2 单季首末为 +8.92 分。这些比较的起止窗口并不相同，只用于判断方向是否依赖定义；末季严格 $n < 5$ ，不据此解释当季前沿涨跌。

9.6 规模与剩余时间项

主模型在 32 个独立基础发布上拟合 $\text{logit}(S/100)=\beta_0+\beta_C(\log_{10} C-23)+\beta_T t$ ， $\beta_C=0.696$ 、 $\beta_T=0.270$ 。C4 参数 N、训练数据 D、reported compute 均已读取；N+D+time 替代模型仅使用 D 完整子样本，见比较表。三个主候选的跨组织/家族验证误差：time_only 11.10，compute_only 7.05，structural 7.10，nd_time 6.35。结构模型没有优于 compute-only，时间项的识别弱。

9.7 模型类型敏感性

开放权重主样本 pretrained 32、chat/finetuned 10；同一模型在 C1 存在类型冲突时，按同日较高能力提交去重，分类本身存在不确定性。有 reported compute 的 chat 模型过少，不能可靠分开估计 chat 的规模/技术贡献。两类能力前沿已分别列出和绘图。

9.8 算力前沿

C4 对所有公开权重 Language 模型筛选 Confident/Likely、reported FLOP、发布日期在零点以前，2025Q1 为不完整季度而排除。2021 - 2024 的单斜率年对数增长 1.301（约 3.67 倍/年）；2023 - 2024 近期斜率 1.982（约 7.26 倍/年）。piecewise BIC=-4.22，单斜率 BIC=-7.12，未形成可靠的已放缓证据；近期 p90 波动较大。

9.9 任务差异

六维榜单没有模型达到任一项90分，当前样本无直接 ceiling；任务族 IFEval 高于其他部分任务，未来有界 logit 仍必要。C8 的 math 子任务族前沿增长最明显，但季度模型构成变化可能造成选择偏差。

9.10 冻结原点的能力情景

下表是 T1 下的探索性有界前沿；区间是参数 bootstrap 加样本残差的条件区间，未涵盖未来数据源与制度变化。能力锚取严格 W1 末季，仅 2 个模型，frontier_forecast_12m_24m.csv 已逐行标记该样本仍有提升空间状态。没有12/24个月直接观测回测，不得用作可信的点预测。

月数	算力情景	点估计	条件80%区间	条件95%区间
12	continuation	50.81	[34.30, 76.50]	[25.87, 91.61]
12	moderate_slowdown	43.37	[27.75, 70.10]	[20.89, 88.73]
12	strong_slowdown	39.73	[24.12, 68.73]	[17.84, 87.26]
24	continuation	71.13	[46.64, 95.27]	[33.53, 99.65]
24	moderate_slowdown	57.51	[32.05, 92.13]	[22.14, 99.15]
24	strong_slowdown	50.09	[25.00, 90.65]	[16.67, 99.09]

9.11 由资源配置到能力的机制链

问题一采用 P1 观测支持域配比作敏感性；问题二读取 V2 Model C 参数；问题三 V2 在 E0/E1/E2 约束下把未来算力转为 N/D/Q 与 Loss；C6 logistic 桥接转为分数。主对照使用 P0 基准配比、E1 3× 边界。E1 在这些算力情景达到 N/D 上限，故其能力预测近乎不随算力变化，属于资源边界假设的结果。P1、E2 及超出 C6 Loss 范围均已标记。

9.12 两种情景路径对照

中度放缓 12/24 月：数据驱动 43.37/57.51，机制 20.94/20.94，差 22.43/36.58 分。机理表另给桥接 CV RMSE 推出的误差带，此带没有覆盖率保证。主要不一致来自小样本时间趋势外推、C6 Loss 定义/后训练差异及 E1 N/D 上限；不人为校准相等。

9.13 不确定性、回测与限制

组外桥接 RMSE 11.86 分。可用季度数据只有 4 季，直接时间模型 3 个月滚动回测 2 折，RMSE=7.96 分。另以每个预测原点当季观测 p95 不变为朴素短期持平基线，在相同原点与目标季度比较：

原点→目标	提前月数	目标季 n	直接时间趋势绝对误差	持平基线绝对误差
2024Q3→2024Q4	3	5	11.11	5.73
2024Q4→2025Q1	3	2	1.85	2.16
2024Q3→2025Q1	6	2	18.80	7.89

3 个月的 2 个目标上，直接趋势 MAE=6.48 分，持平 MAE=3.95 分；但全部 3 个回测对里，要求目标季 n≥5 后仅剩 1 个，无法据此升级长期模型。持平基线只作为短期预测的风险参照，不替换 12/24 个月数据驱动或机制路径。12个月 0 折、24个月 0 折；长期区间不是经历史覆盖率校准的预测区间。bootstrap 组织重采样、算力与技术情景、桥接分层、问题三外推分别列出，不能将混合范围叫作95%置信区间。逐行对照见 short_term_baseline_comparison.csv。




图 7 Loss—能力单调桥接及样本分布

表 6 问题四能力模型的关键验证

对象	协议	结果	证据边界
六基准能力指数	严格开放权重匹配	45 个独立模型	末季仅 2 个
C6 logistic 桥接	模型家族 GroupKFold	RMSE 11.864 分	高可比 7 行且同属一族
仅算力历史模型	组织/家族分组	RMSE 7.052 分	32 个基础发布
算力加时间模型	同上	RMSE 7.103 分	不优于仅算力模型
12/24 月情景	2025-01-31 冻结原点	33.47—50.81 / 36.88—71.13 分	情景包络，非覆盖率区间




图 8 历史能力前沿与冻结原点条件情景

9.14 测量、桥接和时间情景的数学关系

设六项任务分数为 $s_1, \dots, s_6$ ，能力指数 $S = \frac{1}{6} \sum_{k=1}^6 s_k$ 。这固定了汇总口径，避免按现有模型的表现反向调整权重。C6 桥接采用单调有界 logistic $\hat{S}(L) = 100/[1 + \exp(a + bL)]$ ，系数方向约束使 Loss 较低对应能力不下降。训练权重 1 与 0.35 仅反映高、中可比样本的敏感性设定；高可比样本仅 7 条且同属一个家族，因此独立验证必须按家族分组。

历史季度 p_{95} 描述严格样本的上沿，不是整个开源生态的无偏估计。算力加时间的结构分解属于给定模型形式下的对称反事实，且模型的隐含首末变化与观测方向相反，所以不报告“技术贡献的实证份额”。冻结原点的情景把未来算力增长

与剩余时间项逐一组合；包络仅是情景集合的取值范围，不是具有已校准覆盖率的预测区间。

9.15 逐任务能力

同一叶任务只使用预先固定的评价指标：BBH、GPQA、MUSR 为 `acc_norm,none`，MATH 为 `exact_match,none`，IFEval 为 `inst_level_strict_acc,none`，MMLU-Pro 为 `acc,none`。先在相同 `task/metric` 内计算百分位 r_{ij} ，再令 $\text{DetailedAbility}_i = \text{mean}_j r_{ij}$ 、 $\text{WeakAbility}_i = \text{Q25}_j r_{ij}$ 。父任务与子任务不重复计数；至少50%任务覆盖与三个任务族。百分位是样本相对指标，不能与榜单0-100原始分直接减法比较。用同模型的相关性和名次差检查它是否支持六维主指标。

9.16 桥接模型

模型族分组折中，同一系列绝不同时出现在训练与测试。线性桥接为 $S = a + bL$ ， $b < 0$ ；有界桥接为 $S = 100 \cdot \text{sigmoid}(a + bL)$ ， $b < 0$ ；isotonic 为单调非增的经验阶梯函数，在训练Loss范围外为常数。主报告选择有界桥接以保证预测量纲与0-100边界，并以分组CV报告其泛化误差。High-only样本集中于少数系列，不能把其拟合优度看成跨模型族性能。C5只作对照，不增补C6主表。

9.17 规模与剩余时间趋势

主回归在验证过的独立发布上为 $Y_i = \beta_0 + \beta_C(\log_{10}(C_i) - 23) + \beta_T t_i + \text{error}_i$ ， $Y_i = \text{logit}(S_i/100)$ ， t 以2024-01-01起算年数。训练算力来自C4 reported FLOP；C4的N、D用于参数冲突检查、proxy和 $Y \sim \log_{10}(N) + \log_{10}(D) + t$ 替代模型。独立发布去重避免一次模型多次提交扩大样本量。用组织分组CV检查拟合。由于时间与算力同时变化， β_C 还包含未观测数据质量、后训练、评测适配与样本选择；它不是特定算法的因果效应。

9.18 对称反事实分解

以历史首季度观测p95能力为 s_{00} ，把算力从首季p90切到末季p90、把时间从首季切到末季，构造 s_{10} 、 s_{01} 、 s_{11} 。算力贡献为 $[(s_{10} - s_{00}) + (s_{11} - s_{01})]/2$ ；剩余时间贡献为 $[(s_{01} - s_{00}) + (s_{11} - s_{10})]/2$ 。两者精确加到 $s_{11} - s_{00}$ 。组织聚类bootstrap重拟合回归，再逐次分解。模型隐含变化与实际 p95 变化方向相反的诊断被保留；这比只报告模型内百分比更重要。等效算力倍数为 $10^{(\beta_C \Delta t / \beta_C)}$ ，仅在 $\beta_C > 0$ 时解释。

9.19 未来情景

C4开放语言模型季度p90算力序列作为外生资源路径；排除不完整季度。其2023-24对数年斜率记为 g 。未来第 h 年资源为 $C_h = C_0 \exp(g \cdot h \cdot \text{scale_factor})$ ， scale_factor 为1、0.5、0.25。技术残差 $\beta_T h \cdot \text{tech_factor}$ ， tech_factor 为1、0.5、0。能力预测在最后观测p95的 logit 上累加两项再反变换。组织bootstrap的系数分布加历史残差形成条件区间；不同情景形成包络，与条件区间概念不同。因为历史开源能力前沿只有四季，12/24个月滚动原点没有可用折，表中的长期数值不可视作已校准预测。

9.20 问题一至三的机制链

读取问题二 V2 的 Model C 参数与问题三 V2 的求解函数，在给定C下得到E0、E1、E2的N、D、Q和 Loss。问题一的P1观测支持域配比通过问题三V2已审计的 delta_p 传入；主对照采用P0参考配比，P1仅作 $\lambda = 0.25$ 敏感性。再将Loss输入C6桥接。E1的3倍N/D上限在所有未来算力情景中都被触及，所以E1出现平坦的机理预测；这揭示的是机制约束与外推范围，而非前沿必定停滞。C6分组CV误差带和强外推标记与机制结果一同输出。

9.21 历史前沿的样本选择与解释门槛

主口径要求 C1 榜单实体与 C4 元数据的模型名和发布方直接匹配，且六项能力分数完整、权重开放状态明确。严格筛选保留 45 个模型，季度样本数为 22、16、5、2。前沿用季度 p95 而非单个最高分，以减少偶然极值的影响；但末季两个模型仍不足以稳定解释该分位数。预设 $n \geq 5$ 才解释季度方向，故 2025Q1 仅列描述值。宽松实体继承的 C2 口径可产生相反走势，说明样本定义与真实变化尚不能分离。

算力与发布时间不是随机赋值变量。更大的模型往往同时拥有不同训练数据、架构、后训练、评测适配和开放策略。仅算力历史模型在 32 个基础发布上的分组 RMSE 为 7.052 分，加入时间项后为 7.103 分；加入变量没有改善组外预测。即使结构分解可以计算算力与时间项的模型内反事实，也不宜写作“历史能力增长中技术贡献占比”。该结论的必要证据应是同口径、更长时间序列及可识别的机制对照。

9.22 桥接误差怎样进入能力情景

令问题三输出的条件 Loss 为 L^* ，问题四桥接为 $\hat{S}(L^*)$ 。在局部范围内，Loss 输入误差 δL 造成的分数变化近似 $\hat{S}'(L^*) \delta L$ 。然而 C6 的家族组外 RMSE 11.864 分还包含来源口径、不同模型族及 Benchmark 测量差异，这一误差不能由 Loss 导数消去。若 P3 高预算 E1 配置钳在 N/D 上限，未来算力增加也可能不改变其 L^* ，于是经桥接得到的能力情景趋于平坦；这是资源边界假设的结果，不是能力增长会停滞的实证预测。

12/24 月的九条情景来自三种算力增长与三种时间项。12 月中位结果范围 [33.47, 50.81] 分，24 月范围 [36.88, 71.13] 分；最末季度锚点 $n=2$ ，且不存在同期直接回测。因此范围不能作为可承诺的分数区间，也不能从 2026 年 9 月的视角将 2026-01-31 目标日称作未来预测。本文保留 2025-01-31 冻结原点，以便审查当时已有数据所能支持的条件推演。

9.23 规模与剩余时间项的条件分解

为回应题目对规模扩张和非规模因素的比较，结构模型在固定样本上把 $\log_{10} C$ 与发布时间 t 同时放入能力 logit 回归，并以两种先后次序的平均构造对称反事实分解。已有计算对首末季度给出模型隐含总变化 6.84 分，其中规模路径 2.15 分、时间路径 4.69 分，对应模型内份额 31.5% 与 68.5%。但严格样本实际 p95 首末变化是 -2.80 分，模型隐含变化与观测方向相反；最近季度又只有 2 个模型，未过解释门槛。因此这些百分比只保留在附录作为“给定结构模型形式会产生何种分解”的诊断，不作为历史贡献的实证比例，更不把剩余时间项命名为已识别的技术因果效应。

不报告实证份额本身是模型检验结果：它表明现有严格开放权重样本、算力元数据与短时间跨度不足以稳定分离规模和 非规模进步。为了保留对竞赛问题的回答，正文报告组外预测的比较（仅算力 RMSE 7.052 分、算力加时间 7.103 分），

并给出分解失败的具体证据。未来若有同口径更长序列、成对基础/后训练记录或可解释的技术干预，再重新估计贡献比；不能通过对当前末季的两个模型增权来获得可信份额。

9.24 六基准汇总与逐任务交叉检查

六项 Benchmark 的等权均值提供固定、可复核的总体口径，却可能掩盖单项饱和、任务难度差异和模型类型差异。C8 逐任务汇总与六基准指数的 Spearman 相关为 0.9527，说明在同源任务覆盖足够的模型上，两个汇总排序大体一致；这不是新的独立能力真值。对单个模型或任务族的实际应用，仍应查看任务层分数和覆盖率，不可把总体均值等同于所有能力维度同时提高。

严格主样本同时包含预训练基础模型与 chat/finetuned 模型，但两类模型的任务分数和发布时间构成不同。分层前沿图显示不同类型样本量有限，不能稳定分别估计其算力/时间贡献。C4 中的开源权重状态、训练算力和数据量也有缺失或实体匹配歧义，故只在明确通过筛选的 45 个模型上定义 W1 主前沿；宽松继承匹配作为口径敏感性，不将其较多样本误认为更高质量证据。

10 模型综合检验

10.1 预测误差与负面结果

表 7 全文模型检验汇总

环节	验证方式	已观察结果	尚不能支持的结论
P1 配比	五折嵌套 OOF、既定规模回顾性评价、配对 bootstrap	1M RMSE 0.2543; 1B 8/13 域改善	全域优越、跨规模绝对 Loss 精准
P1 质量	权重与冲突阈值敏感性	四组等权代理可审计	人工质量真值有效性
P2 标度	留 N、B7 新点、B8 异机制、B2/B4/B5 raw	Q×N 在 B6/B7 优于加性项	跨来源通用质量因果律
P3 规划	预算消元、KKT、联合 bootstrap、上界/成本情景	条件最优数值可复核	E1 为现实唯一最优
P4 能力	家族 GroupKFold、口径敏感性、季度 n 门槛	桥接 RMSE 11.864 分	精确长期能力预测

10.2 稳健性与灵敏度

P1 的 Q 权重、ALR 参照域与零替换检验的是定义稳定性；P2 的 Q×N×D 候选检验复杂度代价，B8 检验机制相容性；P3 的三种质量成本、Q_0、上下文和 E0/E1/E2 上界检验决策稳定性；P4 的严格/宽松实体匹配、能力任务和桥接可比权重检验测量口径。上述检验的条件不同，不能汇成单一“稳健率”。

10.3 跨问误差传播

P1 的配比模型进入 P2 的形式是 Δ_p，跨规模幅度 λ_p 未识别；P1 的 Q_A 不数值替代 P2 的 Q_B。P2 的标度参数与半合成质量项一起决定 P3 条件最优，P3 的上界和成本假设常比求解器数值误差更主导高预算配置。P4 将 P3 的 Loss 经 C6 桥接转成能力分数，其 11.864 分组外误差和不同来源 Loss 口径共同限制能力解释。因此报告条件链条而不声称四问联合实验已验证。

10.4 未通过的证据门槛

选定链的 P4 验证共 34 项，通过 31 项。未通过的是 12 月直接回测、24 月直接回测及历史分解与观测前沿一致性；这些是证据不足或模型诊断，不能通过改写为“通过”消除。

10.5 对全链结论的分层判定

评估一条跨问结论时，先看它在哪个样本单位上被观测，再看接口是否使用真实共享变量，最后看结果需要多少外推。第一层为 A4/A5→A6/A7 的配比模型比较、B6→B7 的同机制新点、P3 给定参数下的预算计算和 C6 家族隔离桥接；它们都有对应的运行或记录。第二层为 P1 配比差分注入 P2、P2 参数注入 P3；代码读取是真实的，但不同损失量尺和 λ_p 的含义仍需条件化。第三层是 Q_A→Q_B 质量换算、1M 配比到大规模的确定收益及未来能力点值；项目当前没有联合锚点或直接回测，所以只能保留为情景。

表 8 跨问接口与误差传播位置

箭头	进入下游的量	当前证据	主要误差或假设
P1 配比 → P2	相对配方 Loss 差 Δ_p	系数直接嵌入	λ_p(N) 未由多规模受控训练识别
P1 质量 → P2	Q_A 与 Q_B 的概念联系	无共同数值锚	两量尺不能直接相等
P2 → P3	N-D-Q_B 条件 Loss 参数	artifact 直接读取	B1/B6 来源口径及外推范围
P3 → P4	情景 N、D、Q_B、Loss	复用求解方法重算	上界、成本与配比条件
Loss → 能力	C6 logistic 桥接	家族组外 RMSE 11.864 分	Loss 可比性及模型族差异

这张表也解释了为什么最终结果不能把各环节 RMSE 简单相加或相乘。P1 的 13 域 pooled RMSE、P2 的验证 Loss RMSE 和 P4 的能力分数 RMSE 单位不同；P3 的 KKT 误差则是数值最优性检查，根本不是预测误差。可行的传播方式是对同一设定依次改变上游参数、λ_p、成本结构和桥接参数，观察最终能力情景的条件变化，并逐项保留来源标签。已有项目的联合参数重抽样、λ_p 情景和桥接敏感性分别提供局部剖面；由于没有 A/B/C 联合样本，不能拼成具有已校准覆盖率的“总置信区间”。

10.6 评委可复核的反例与限制

第一，若只看 P1 的 1M 指标，CLR 样条会被选中；加入 1B 总体误差后，结论改变。第二，若只看 B1 的同族 0.000151 留组误差，会高估模型跨来源的绝对预测能力；B2/B4/B5 raw 误差揭示量尺偏移。第三，若只看 P3 的 10^{24} E2 最低 Loss，会忽略其 D 约为 B1 最大观测值的 12.2 倍；E0/E1 虽预算剩余较多，却把可检验证据边界写清。第四，若只看 P4 的严格季度 p95 曲线，会把 n=2 的末季变化错当趋势；宽松匹配又给出不同方向。这四个反例共同说明，模型复杂度或单项分数都不能替代样本口径、验证协议与适用边界。

11 模型评价与推广

11.1 模型优点

分层结构让质量、配比、规模、成本与能力各在其可观测层估计，并记录接口的可信程度。ALR 处理 17 域闭合约束，多任务收缩改善既定 1M 配方集的总体预测；Q·B×N 在半合成新点中保留组外收益；D 的解析消元让规划的活动边界、KKT 和上界敏感性可解释；家族隔离检验使能力桥接避免同族样本穿越训练与测试。

11.2 局限与改进方向

缺少人工质量真值、A/B 共同质量锚点和多规模独立配比实验，限制 Q_A、Q_B 与 λ_p 的联合识别。B1 同族精密拟合不能抵消跨源 raw Loss 偏移。E1 三倍上限是条件选择，E2 超观测域；C6 桥接误差较大，前沿末季样本稀少，历史时间分解与观测变化方向不一致。后续应以同口径受控训练、人工盲评和滚动前沿样本补证，而非增加未经验证的模型复杂度。

11.3 实际应用价值与结论

在预算和成本规则明确、N/D 落在观测或清楚标注的外推范围时，模型可生成候选训练配置、质量投资转折点与对上界的敏感性剖面。问题一的质量分用于筛选线索，配比模型用于支持域内相对比较；问题二的条件 Loss 用于比较同机制候选；问题三的 E0/E1/E2 用于展示资源决策的证据代价；问题四的能力情景用于讨论假设变化下的可能范围。所有数值应随数据口径、验证协议与情景边界一同使用。

11.4 面向训练方案的使用步骤

实际使用时先确定可观测输入和不可观测输入。已掌握的部分包括预算 C、候选 N/D 范围、上下文长度、成本函数与候选配比；未掌握的部分可能是语料质量能否与 B 组 Q_B 对齐、来源 Loss 的截距或 λ_p 的跨规模幅度。对不可观测输入，先列出保守到积极的有限情景，不用单个拟合参数掩盖其不确定性。

其次固定证据上界。若目标是从已有规模规律获得稳妥的方向，应先看 E0 观测域；若考虑超越已见数据的设计空间，再比较 E1、E2 对 Loss 与预算使用率的改变，同时说明新增外推倍数。 10^{24} FLOPs 的三档结果表明，最小条件 Loss 与最小证据风险并非同一个目标，因此论文给出剖面而不代替决策者选择风险容忍度。质量成本参数和 Q_0 也应来自具体数据处理工艺；若只能使用题设三种形式，就把三者作为并列成本情景，不赋予主情景统计概率。

最后把能力分数作为沟通量，而不是优化目标的精确反馈。P3 的直接输出是验证 Loss；P4 的桥接在家族隔离下仍有 11.864 分 RMSE，且 Loss 跨来源可比性未完全统一。可用能力情景比较“若算力增长放缓或上界改变，结论方向是否变化”，但不能以情景中位数承诺某发布日期的 Benchmark 分数。若新的同口径训练或能力记录到来，应依次更新质量校准、配比尺度效应、标度参数、成本约束和桥接；在这之前，保留每个输入和每项结论的证据标签。

参考文献

- [1] Aitchison J. The statistical analysis of compositional data. *Journal of the Royal Statistical Society: Series B*, 1982, 44(2): 139–160. DOI: 10.1111/j.2517-6161.1982.tb01195.x.
- [2] Li J, et al. DataComp-LM: In search of the next generation of training sets for language models. *NeurIPS Datasets and Benchmarks*, 2024.
- [3] Liu Q, et al. RegMix: Data mixture as regression for language model pre-training. *ICLR*, 2025.
- [4] Hoffmann J, et al. An empirical analysis of compute-optimal large language model training. *NeurIPS*, 2022.
- [5] Biderman S, et al. Pythia: A suite for analyzing large language models across training and scaling. *ICML*, 2023.
- [6] Ye J, et al. Data Mixing Laws: Optimizing data mixtures by predicting language modeling performance. *ICLR*, 2025.
- [7] Gadre S Y, et al. Language models scale reliably with over-training and on downstream tasks. *ICLR*, 2025.
- [8] Ho A, et al. Algorithmic progress in language models. *NeurIPS*, 2024.

附录 A 数据与预处理

完整规则、字段与样本说明仅用于复核 Q_A 的构造，不构成人工质量标签。

A.1 22 项信号规则

字段	类型	压缩	原始方向/效用	统一缩放	缺失数
fineweb_edu	list	单元素取值	越高越好	A1 固定 1%-99% 截尾 MinMax	0
fluency_en	list	两类 logits 中正向类概率	越高越好	A1 固定 1%-99% 截尾 MinMax	0
modernbert_cleanliness	list	六级 logits 的 softmax 期望/5	越高越好	A1 固定 1%-99% 截尾 MinMax	0
modernbert_readability	list	六级 logits 的 softmax 期望/5	越高越好	A1 固定 1%-99% 截尾 MinMax	0
modernbert_reasoning	list	六级 logits 的 softmax 期望/5	越高越好	A1 固定 1%-99% 截尾 MinMax	13
modernbert_professionalism	list	六级 logits 的 softmax 期望/5	越高越好	A1 固定 1%-99% 截尾 MinMax	6
dsir_books	number	原始标量	越高越好	A1 固定 1%-99% 截尾 MinMax	0
dsir_wiki	number	原始标量	越高越好	A1 固定 1%-99% 截尾 MinMax	0
dsir_math	number	原始标量	越高越好	A1 固定 1%-99% 截尾 MinMax	0
qurater	list	四个 QuRating 维度均值	越高越好	A1 固定 1%-99% 截尾 MinMax	0
ad_en	list	两类 logits 中正向类概率	越高越好	A1 固定 1%-99% 截尾 MinMax	0
rps_doc_word_count	number	原始标量	适中最好；经验梯形效用	A1 固定分位点梯形效用	0
rps_doc_num_sentences	number	原始标量	适中最好；经验梯形效用	A1 固定分位点梯形效用	0
rps_doc_unigram_entropy	number	原始标量	越高越好	A1 固定 1%-99% 截尾 MinMax	0
rps_doc_frac_unique_words	number	原始标量	越高越好	A1 固定 1%-99% 截尾 MinMax	0
rps_doc_frac_noun_phrases	number	原始标量	越低越好	A1 固定 1%-99% 截尾 MinMax	0
rps_doc_frac_chars_top_2gram	number	原始标量	越低越好	A1 固定 1%-99% 截尾 MinMax	0
rps_doc_frac_chars_top_3gram	number	原始标量	越低越好	A1 固定 1%-99% 截尾 MinMax	0
rps_lines_uppercase_letter_fraction	number	原始标量	适中最好；经验梯形效用	A1 固定分位点梯形效用	0
rps_lines_ending_with_terminal_punctuation_mark	number	原始标量	越高越好	A1 固定 1%-99% 截尾 MinMax	0
rps_lines_numerical_chars_fraction	number	原始标量	适中最好；经验梯形效用	A1 固定分位点梯形效用	0
rps_doc_mean_word_length	number	原始标量	适中最好；经验梯形效用	A1 固定分位点梯形效用	0

A.2 数据切分、评价指标与单位

为了保证各表中的 RMSE、排序相关和能力分数具有明确分母，本附录把四问的样本单位与训练、评价角色集中列出。A 组的文本记录、配方记录和模型规模检验是不同层次的样本；B1 的连续检查点来自同一模型族，因而分组验证以完整参数规模为单元；C 组的榜单条目、独立模型和季度前沿也不应混为同一个样本数。

模块	原始或评价单位	训练/评价安排	主报告指标
质量代理	A1 51,230 、 A2 17,523 、 A3 203,752 条信号	A1 固定分位映射，A2/A3 去重扩展核查	领域均分、冲突率、条件区间
配比回归	A4/A5 512 个 1M 配方，每个有 13 个验证域	五折嵌套训练内选择；A6/A7 1M、60M、1B 既定比较	pooled RMSE、MAE、逐域 RMSE、Spearman
规模律	B1 1,176 行，含 8 个参数规模	留完整 N 组；B2/B4/B5 保持原始来源口径	组外 RMSE、跨源原始 RMSE
质量项	B6 360 行；B7 去重后 90 个新输入	B6 留 N 组；B7 新点评价；B8 机制对照	条件 RMSE、组级重抽样差
预算配置	三档 FLOPs、三种质量成本、多种支持域上界	对每个情景重新优化，统一 free oracle 比较	条件 Loss、预算使用、后悔值

模块	原始或评价单位	训练/评价安排	主报告指标
能力前沿	C1 4,576 条榜单；严格 W1 45 个独立模型	六基准完整记录、实体直接匹配、季度 p95	前沿分数、季度样本数
桥接	C6 75 条记录、23 个家族	家族隔离五折	能力 RMSE（分）

pooled RMSE 对所有配方与验证域误差汇总后开方，因此能够反映总体预测尺度；逐域 RMSE 则先按域分别汇总，用于检查误差异质性。配方级 bootstrap 按配方行重抽样，保留同一配方的 13 个输出之间的相关结构。表中的条件 95% 区间描述给定数据和重抽样单位下的估计变动，不覆盖数据来源差异或未来模型训练中的变化。训练内嵌套交叉验证的外折预测用于模型选择评价，既定跨规模配方集保持原有标签，仅作为回顾性结果。

B1 参数组留出与 B6 参数组留出虽然都记作组外误差，样本来源不同。B1 的同族轨迹在 8 个参数规模之间共享训练设计；B6 是半合成质量机制。B2/B4/B5 的原始 RMSE 检查统一公式跨来源的绝对损失口径；有目标标签的来源校准另列协议，不与零样本评价合并。B8 的同输入异标签结构用于检验统一函数的适用范围，不参与 B6 质量参数的主选型。

在问题三，单情景最优和共同可行政策的约束集合不同。正文的 E0/E1/E2 表使用指数成本、 $Q_0 = 0.6$ 、4096 Token 上下文，显示同一预算下外推边界的作用；稳健政策在所有选定结构情景下满足预算。跨上界的后悔值共用自由 oracle，使 $1\times$ 、 $2\times$ 、 $3\times$ 、 $5\times$ 和 free 剖面可比较。质量起投和饱和阈值是固定成本函数与中心参数下的数值切换点，不是统计区间。

在问题四，C1 的全部榜单记录首先按来源实体去重、开放权重状态与六基准完整性筛选，随后形成严格 W1 的 45 个模型。季度 p_{95} 的样本数依次为 22、16、5、2，最后一季只作为描述值。C8 的逐任务汇总是与主六基准相关的内部核查；C6 的 75 条记录用于 Loss - 能力桥接，不能把其家族分组误差等同于能力前沿时间预测误差。12/24 个月情景的原点固定于 2025-01-31，输出的中位数范围是九种设定的包络。

符号	定义	单位或约束
N	模型参数量	十亿参数；成本式中还原为参数个数
D	训练 Token 数	十亿 Token；成本式中还原为 Token 个数
Q_A	A 组四类文本信号等权代理	$[0, 1]$ ，固定规则的相对指标
Q_B	B6/B7 质量控制列	$[0, 1]$ ，与 Q_A 量尺未直接校准
$\mathbf{p}$	17 域训练配比	单纯形， $p_i \geq 0$ 且 $\sum_i p_i = 1$
L	验证集交叉熵损失	附件损失口径，数值越低越好
S	六基准等权能力指数	0 - 100 分，数值越高越好
C	总算力预算	FLOPs
L_{ctx}	外生上下文长度	Token
$g(Q_B)$	每 Token 的质量处理成本函数	题设的指数、幂或对数情景
λ_p	配比效应跨规模幅度	未由联合受控数据估计；参考情景取 1

公式中的 N, D 在标度律里使用十亿单位，成本式中训练项为 $6 \times 10^{18} ND$ 。上下文成本为 $2 \times 10^{14} NDL_{ctx}$ ，与训练项同量级时 $L_{ctx} = 30,000$ 。质量处理项为 $10^9 D[g(Q_B) - g(Q_0)]_+$ ；当 $Q_B \leq Q_0$ 时该增量取零。

A.3 结果来源索引

质量与配比源文件：`problem1/quality_pipeline.py`、`rebuild/problem1/paper_key_numbers.csv`、`rebuild/problem1/metrics_by_scale.csv`。标度律源文件：`rebuild/problem2/paper_key_numbers.csv`、`rebuild/problem2/model_card.md`。预算优化源文件：`rebuild/problem3/paper_tables/`、`rebuild/problem3/problem3_decision_tournament.csv`。能力源文件：`rebuild/final_review/outputs/tables/problem4_quarterly_frontier.csv`、`rebuild/final_review/outputs/tables/problem4_scenario_envelope.csv`、`rebuild/final_review/verification/problem4_model_card.md`。四问上下游选定链见 `rebuild/final_review/verification/selected_lineage.json`。

附录 B 问题一补充实验

本附录完整保留研发过程中的早期 V1/V2 候选，参数与主文最终选定模型不同；这些表不替代主文的选定链结果。

本附录记录模型开发阶段的基线、候选及跨规模诊断，以说明正文最终选型的来由。涉及原始 V1/V2 的表格保持其历史实验口径；正式跨问预测使用正文与选定链的规格。

17 域领域配比模型

设 $p_i \geq 0$ 、 $\sum_{i=1}^{17} p_i = 1$ ，观测响应为 13 个验证域 Loss L_k 。无截距约束的 17 比例与截距线性相关，因此简单基线删去一列，主模型用 additive log-ratio：

$$x_i = \log \frac{p_i + \epsilon}{p_{17} + \epsilon}, \quad i = 1, \dots, 16, \quad \hat{L}_k = b_{0k} + \sum_{i=1}^{16} b_{ik} \text{ standardize}(x_i).$$

其中参考域为 `uspto_backgrounds`，零替换 $\epsilon = 0.000499$ （训练集最小正配比的一半），Ridge 惩罚系数由 A4/A5 五折 CV 确定为 1。比较均值、删参考域原始比例 Ridge、ALR Ridge、二阶多项式 Ridge 与 ExtraTrees。模型的输入只有配比，输出同时预测 13 个验证域 Loss，模型比较按 13 维总体 RMSE，亦报告每域平均 R^2 和 Spearman。

模型	1M MAE	1M RMSE	1M MAPE	13 域平均 R^2	13 域平均 Spearman
<code>alr_ridge</code>	0.253	0.341	5.3%	0.790	0.907
<code>extra_trees</code>	0.336	0.403	6.7%	0.588	0.798

模型	1M MAE	1M RMSE	1M MAPE	13 域平均 R ²	13 域平均 Spearman
quadratic_ridge	0.352	0.500	7.5%	0.665	0.835
raw_ridge	0.386	0.523	8.4%	0.619	0.830
dummy	0.619	0.780	13.6%	-0.012	—

ALR Ridge 在训练集内部 CV 的 RMSE 为 0.394，并在 A6/A7 上取得最低 RMSE。二阶交互模型的测试 RMSE 更高，故交互系数仅作探索。A8 – A11 未用于训练或调参。

质量映射是否改善配比预测

A16 只有 6 个 `direct/near_direct` 域可较可靠地连到质量域。对其定义已映射部分的质量加权均值和已映射配比总量，与 ALR 特征并列加入 Ridge，保持其余 11 域为未知。实验结果如下：

模型	训练 CV RMSE	1M RMSE	60M RMSE	1B RMSE
ALR+mapped_Q	0.3902	0.3374	1.6070	2.9847
ALR_only	0.3937	0.3415	1.6093	2.9820

加入映射质量后 1M RMSE 略降，但 1B 略升；更关键的是域级 Q_d 对所有配方固定，新增特征是 $\mathbf{p}$ 的确定性函数，不能从这份实验独立识别质量的作用。因此问题一的主配比模型仍为 $L = f(\mathbf{p})$ ； Q 保留为问题二的跨来源融合输入，不将 11 个未知域伪装成实测质量。

外部检验与外推稳健性

以下所有行使用在 1M 训练数据选出的同一个模型，未用大尺度检验标签做截距校准：

数据集	标签性质	RMSE	平均偏差：预测-真实	域内 Spearman 均值
test_1m	observed	0.341	0.054	0.907
test_60m	observed	1.609	1.513	0.903
test_1b	observed	2.982	2.911	0.888
est_10b	estimated_extrapolation	3.605	3.552	0.695
est_70b	estimated_extrapolation	3.993	3.934	0.628

以训练集 ALR 特征的最近邻距离衡量配比空间支持，用训练集留一最近邻距离的 95% 分位作阈值：

数据集	超出训练局部支持	与训练配比完全相同	外推轴
test_1m	5.86%	0.00%	mixture-space
test_60m	5.86%	0.00%	parameter-scale
test_1b	0.00%	0.00%	parameter-scale
est_10b	0.00%	100.00%	parameter-scale; labels estimated
est_70b	0.00%	100.00%	parameter-scale; labels estimated

60M、1B 的绝对预测均系统性偏高，说明模型未包含参数规模的整体 Loss 漂移；但域内排序相关仍较高。10B/70B 的配比与训练配比完全重合，故是参数规模方向的外推，而非新配比空间的外推；其 Loss 是题目附件中已有模型的外推估算，不是新的实测验证。其误差和相关仅说明与该估算表的一致程度，不构成 10B/70B 真实泛化证据。任何跨尺度论文表述必须区分数值预测与配比排序。

领域置换效应及交互

单纯形上“增加某域”必须同时“减少另一域”。在训练配比均值附近，以 `pile_cc` 为参考域，将其比例减少 1 个百分点并增给另一域，计算 13 个验证域平均 Loss 的预测差。以下区间来自 A4/A5 的 300 次配方级 bootstrap，属于该模型和该局部位下的参数不确定性；零值伪计数和领域定义误差未包含其中。

增加域（减少 pile_cc）	预测平均 Loss 差	95% bootstrap CI	方向稳定频率
ubuntu_irc	-0.0155	[-0.0197, -0.0110]	1.000
dm_mathematics	-0.0108	[-0.0136, -0.0075]	1.000
stackexchange	-0.0019	[-0.0028, -0.0008]	1.000
wikipedia_en	-0.0003	[-0.0017, 0.0010]	0.657
europarl	0.0089	[0.0013, 0.0152]	0.993
nih_exporter	0.0255	[0.0136, 0.0373]	1.000
philpapers	0.0273	[0.0130, 0.0425]	1.000
enron_emails	0.1204	[0.0976, 0.1472]	1.000

负数表示预测 Loss 降低。`ubuntu_irc`、`dm_mathematics` 等局部替换在本数据与模型下表现较稳；`enron_emails` 的大幅正值来自其训练占比通常很低、ALR 近零区斜率很大，不宜简单解释为该域绝对有害。完整 17×16 置换矩阵见 `domain_effects.csv`，13 个验证域的分别响应见 `domain_effects_by_validation_domain.csv`。

二阶 Ridge 给出了 120 个候选交互系数，但五折 CV 与 1M 独立检验均劣于主模型；未完成多重比较校正后的独立复现。因此当前没有稳定证据宣称某个域对存在互补或冗余，仅将候选列入 `interaction_effects.csv` 供下一步研究。

稳健性与跨间接口

稳健性证据包括：A1 参考尺度下 A2/A3 的非重合样本对照；CRITIC/鲁棒评分、组权重扰动、均值/中位数与 200 次全样本量 bootstrap；冲突阈值和惩罚系数敏感性；五折训练 CV 与 1M/60M/1B 外部检验；A12 - A15 仅作外推估算对照。脚本、表格和图均可一键复现。

该历史基线的适用范围以 1M 配方和既定测试集为主；A12 - A15 为估算标签。

问题二可接收：domain_quality_scores.csv 中的七域 Q_d 与区间；A16 的映射可信度；quality_weights.csv 与指标统一规则；ALR 配比模型与 A6 - A11 的误差；以及“直接跨尺度绝对 Loss 失效”的实证约束。

领域配比 p 如何加入问题二

定义问题一模型给出的 13 验证领域平均预测 Loss 为 $\bar{L}_p(\mathbf{p})$ ，再中心化：

$$\Delta_p(\mathbf{p}) = \bar{L}_p(\mathbf{p}) - \bar{L}_p(\mathbf{p}_0), \quad \mathbf{p}_0 = (1/17, \dots, 1/17).$$

最终附加 $\lambda_p \Delta_p$ 。中心化使参考配比的修正为零，避免把问题一的绝对预测截距误差搬到 B1 的 Loss 标尺；局部两配比的差分也不依赖参考常数。 λ_p 是跨数据来源/规模的幅度桥接系数，当前 B 数据没有共同的 $(N, D, Q, \mathbf{p})$ 实验来估它；代码中取 1 为基准情景，并做 0.5、0.75、1、1.25、1.5 敏感性，见 bridge_assumptions.json 和 sensitivity_summary.csv。V2 的 p_scale_scenarios.csv 另给常数、 $N^{-0.1}$ 、 $N^{0.1}$ 三种未识别情景，不能把它们当拟合结果。乘法桥接只在 model_candidates.md 提为候选/情景，项目没有证明比加性桥接更好。

p 的跨规模分析

V2 run_v2.py:p_scale_evidence 读取问题一 V1 已保存的 test_predictions.csv 中 alr_ridge 逐配方预测，对同尺度预测/实际去均值后回归幅度，500 次配方 bootstrap 得 p_scale_transfer_from_problem1.csv：

尺度	配方数	centered slope	95% 区间	Spearman
1M	256	0.90018	[0.70634, 1.08762]	0.4920
60M	256	0.65834	[0.49004, 0.83056]	0.4633
1B	64	0.28515	[0.19536, 0.38779]	0.6622

这些是问题一旧版 ALR 模型的探索性幅度，尺度间配方支持域也不同。问题一最终 V2 没有保存同样的跨尺度逐配方预测，故不能由此给 Model C 拟合精确的 $\lambda_p(N)$ 或衰减指数。

最终广义 Scaling Law: Model C

problem2_v2/outputs/models/recommended_model.joblib 的 ND_model=classic、Q_model=quality_model，预测实现在 problem2_v2/models.py:predict_recommended，与 predict_nd, predict_q 一致：

$$L_C(N, D, Q_B, \mathbf{p}) = 1.689797563 + 0.353980321N^{-0.339976582} + 1.240305584D^{-0.279878129} + 0.356807363(1 - Q_B)^{0.991543461}N^{-0.162072924} + \lambda_p \Delta_p(\mathbf{p}).$$

第一项 E 是经典拟合底座；第二项是参数仍有提升空间损失；第三项是 token 仍有提升空间损失；第四项是低质量惩罚， N 越大其绝对幅度按本半合成拟合越小；第五项是相对均匀参考配比的预测修正。 $Q_B = 1, \mathbf{p} = \mathbf{p}_0$ 时退化为经典式。 $\lambda_p = 1$ 是默认情景假设而非拟合参数。公式预测的是不同来源信息拼接后的情景 Loss，不表示五项均被同一联合实验识别。

Model A / Model B / Model C

版本	定义	用途和边界	文件
Model A	V1 classic $+ 0.362175(1 - Q_B)^{0.990735} + \lambda_p \Delta_p$	原始完整基线；Q 对 N 独立	problem2/outputs/models/final_generalized_scaling.joblib
Model B	V2 classic N-D 的来源仿射校准，情景时另附 Model C 的 Q/p	有该来源约 20% Loss 标签时的条件预测；未验证 Q/p 跨源幅度	problem2_v2/outputs/models/model_B_source_calibrated.joblib
Model C	classic + Q×N + 中心化 p	当前论文主模型；B1/B6 参数加可分离桥接	problem2_v2/outputs/models/recommended_model.joblib

Model B 更重视已见目标来源的应用预测，Model C 更适于陈述透明的 N-D-Q-p 结构。B 的校准不会自动改善 C 在未知来源的零样本表现。V1 的旧报告、旧接口、旧导数表均仍真实存在，但没有被 V2 重新生成。

边际效用：从 Model C 推导

固定 $D, Q, \mathbf{p}$ 时， $Q \times N$ 项也随 N 改变，因此

$$\begin{aligned} \frac{\partial L_C}{\partial N} &= -\alpha AN^{-\alpha-1} - \eta_N G(1-Q)^\kappa N^{-\eta_N-1}, \\ \frac{\partial L_C}{\partial D} &= -\beta BD^{-\beta-1}, \quad \frac{\partial L_C}{\partial Q} = -\kappa G(1-Q)^{\kappa-1} N^{-\eta_N} \quad (0 < Q < 1). \end{aligned}$$

上述负号说明增加 N, D, Q_B 在此模型内预测降低 Loss；“改善率”可记为 $-\partial L/\partial x > 0$ 。 $Q \rightarrow 1$ 的导数需看单侧极限： $\kappa \approx 0.992 < 1$ 时理论导数靠近 1 有弱奇异性，有限的 $Q+0.1$ 差分更易解释。 Δ_p 当前实现不显式依赖 N, D, Q ；若未来估计出 $\lambda_p(N)$ ， N 导数还需增加 $\lambda_p'(N)\Delta_p$ ，本项目尚未做到。V1 generalized_scaling.py:derivatives 只适用于旧加性模型，其 $\partial L/\partial N$ 少了 $Q \times N$ 交互项；V2 未保存 Model C 的导数 CSV。

弹性

Loss 弹性定义 $\epsilon_x^{(L)} = (x/L)(\partial L/\partial x)$ ；可约损失 $R = L - E$ 的弹性定义 $\epsilon_x^{(R)} = (x/R)(\partial L/\partial x)$ 。例如 $\epsilon_N = -0.03$ 表示局部 N 增长 1% 时对应 Loss 约下降 0.03%，它是局部近似，不等于翻倍时的有限差分。代入上一节 Model C 导数即可计算新弹性。problem2/outputs/tables/elasticities.csv 现有数值仅属 V1 Model A: $N = 7, D = 300, Q_B = 0.6, \mathbf{p} = \mathbf{p}_0$ 时， $\epsilon_N^{(L)} = -0.0274$ 、 $\epsilon_D^{(L)} = -0.0310$ 、 $\epsilon_Q^{(L)} = -0.0957$ ；可约损失分别约 -0.1071 、 -0.1213 、 -0.3743 。V2 未输出对应 Model C 场景表，不能把这些旧数值标注为 Model C 已运行结果。与成本相结合的边际投入比较留给问题三。

Q_B 提升 0.1 等价于多少参数

固定 $D, \mathbf{p}$ ，先计算质量改善后的目标 $L_C(N, D, Q + 0.1, \mathbf{p})$ ，再求 N_{eq} 满足 $L_C(N_{eq}, D, Q, \mathbf{p}) = L_C(N, D, Q + 0.1, \mathbf{p})$ ，定义倍数 $r_N = N_{eq}/N$ 。V2 models.py:equivalent_N 在 $[N, 10^{12}]$ 上用 brentq 精确求根，若上界仍达不到目标则返回无穷；它不是用导数随意近似。令 $H(N) = AN^{-\alpha} + G(1 - Q)^K N^{-\eta_N}$ ，则求解

$$H(N_{eq}) = AN^{-\alpha} + G(1 - Q - 0.1)^K N^{-\eta_N}.$$

$E, BD^{-\beta}, \lambda_p \Delta_p$ 在两侧相消，所以在该模型结构下倍数与固定的 $D, \mathbf{p}$ 无关。quality_equivalence_by_model.csv 给 $D = 20, 300, 2000$ 三个情景；下表为 $D = 300, Q_B: 0.6 \rightarrow 0.7$ ，70B/120B 远超 B1 最大 11.97B，只能当结构敏感性。

初始 N	V1 加性等价 N_{eq}	V1 倍数	V2 $Q \times N$ 等价 N_{eq}	V2 倍数
0.1B	0.1151B	1.1514×	0.1197B	1.1967×
1B	1.3739B	1.3739×	1.2951B	1.2951×
7B	13.4130B	1.9161×	9.9002B	1.4143×
70B	373.2607B	5.3323×	112.9627B	1.6138×
120B	1047.0793B	8.7257×	200.5827B	1.6715×

V1 的 Q 损失改善幅度与 N 无关，但 $AN^{-\alpha}$ 在大 N 已很小，想靠参数继续降低相同的绝对 Loss，必须把 N 增加很多，故出现 $5 \times / 8 \times$ 。V2 的 $N^{-\eta_N}$ 让质量项也随规模下降，所需额外参数缩小至约 $1.4 - 1.7 \times$ 。这不是“实际加质量一定相当于 $1.4 \times$ 参数”；换 Q 模型或 $Q_A \rightarrow Q_B$ 情景倍数会变化。QA_QB_equivalence_sensitivity.csv 的三个映射仅示范这种敏感性。

领域替代关系

由于 $\sum_i p_i = 1$ ，不能只提高一个领域；应做 $p_i' = p_i + 0.01, p_j' = p_j - 0.01$ ，其余不变，并保证 $p_j \geq 0$ 。V1 run_problem2.py:problem1_bridge 生成的 mixture_effect_summary.csv 是主要结果，见第 3.3 节的五个实例。对同一 λ_p ，广义模型中的损失变化是 λ_p 乘该差分。pile_cc→ubuntu_irc 的 -0.015464 有 bootstrap 区间 $[-0.019659, -0.011023]$ ；pile_cc→dm_mathematics 的 -0.010771 有 $[-0.013631, -0.007453]$ ；pile_cc→stackexchange 的 -0.001851 有 $[-0.002752, -0.000754]$ 。这些只在已有配比支持域附近解释，不能延伸为任意大幅重配方的结论。

领域互补

problem1/outputs/tables/interaction_effects.csv 有问题一的交互项探索，但当前没有同时通过 bootstrap、多个模型规格、样本支持和外部多重比较检验的稳定互补对。当前没有足够证据确认稳定领域互补关系。二阶 ALR 的交互系数也受单纯形约束和变量变换影响，不能看到一个正/负系数就断言两个领域在真实训练中互补。

100B+ 外推

V1 run_problem2.py:analyses 把 B10 估算 Loss 与 B9 元数据按名字、 N, D 一对一连接，在 $Q_B = 1, \mathbf{p} = \mathbf{p}_0$ 参考情景计算 classic 预测，输出 large_model_extrapolation.csv、large_model_metrics_by_band.csv、large_scale_extrapolation.png。128 个估算标签上的 RMSE 0.001093828、MAE 0.000614049、bias +0.000614049、Spearman 约 0.999994，分段 RMSE 为 100-300B 的 0.000676、300B-1T 的 0.001217、>1T 的 0.001923。该数值较低可能因为估算表与经典幂律共用生成规律；B10 不是真实大模型训练 Loss，因此不能称为真实 100B+ 验证。V2 没有另用 B10 选型；Model C 在 $Q_B = 1, \mathbf{p} = \mathbf{p}_0$ 与 classic 完全相同，所以这个参考情景的表可沿用作诊断，但并未检验 $Q \times N$ 或 p 在 100B+ 的效果。

Bootstrap 与不确定性

V1 run_problem2.py:bootstrap 以 B1 的 8 个模型规模为簇做 200 次有放回重采样，每次重估 $N - D$ ，再在同一 B6 表上重估 V1 Q；bootstrap_parameters.csv、parameter_intervals.csv、bootstrap_equivalence.csv 保存结果。它没有按 B6 新抽样 Q 簇，因此 V1 的 G, κ 极窄区间不能解释为完整的质量实验不确定性。V2 run_v2.py:q_experiments 另以 B6 的 N 规模簇做 200 次重采样，固定 B1 参数，输出 quality_model_cluster_bootstrap.csv 和 quality_model_intervals.csv: G 95% 区间 $[0.348694, 0.368501]$ ， κ $[0.950084, 1.036087]$ ， η_N $[0.148572, 0.200805]$ 。两套 bootstrap 是分阶段的，当前项目尚未生成 Model C 全参数联合传播区间。B1 残差相关、来源口径偏差、B8 机制冲突、 λ_p 和 $Q_A \rightarrow Q_B$ 未识别均不包含在这些区间里。

模型选择过程

阶段	模型/动作	为什么试	实际结果	保留?
B1 基线	classic	赛题指定、参数少	同族拟合极好	是， $N - D$ 主干
V1 Q	additive	质量越高惩罚越小、 $Q = 1$ 退化	B6/B7 好，B8 未达到预设条件	基线 A
跨源诊断	B2/B4/B5 raw	检查泛化	B2 大偏移	保留未达到预设条件证据
V2 $N - D$	interaction/compute-ratio/broken/稳健目标	检查复杂结构能否解决问题	无稳定跨源改善；broken 弱识别	不入主模型

阶段	模型/动作	为什么试	实际结果	保留?
V2 Q	六种候选	检查有效 token/饱和/与规模交互	Q×N 的 B6/B7/BIC 最优	主模型 C
V2 校准	截距/仿射/ $\log D$	处理来源损失口径	有目标标签时仿射三源改善	条件预测 B
A/B 融合	中心化 Δ_p	避免绝对 Loss 标尺混用	λ_p 未识别	作为情景桥接
规模替代	精确 N_{eq}	回答题目	7B 约 1.414×; 70B+ 高度外推	附条件报告

参考文献和它们如何影响本项目

problem2_v2/literature_review.md 列出论文和官方代码。Hoffmann 等的 Chinchilla 工作支持以 $E + A/N^\alpha + B/D^\beta$ 作强基线，并把 $C \approx 6ND$ 用作算力约束灵感；本项目没有从其数据移植参数。Caballero 等的 Broken Neural Scaling Laws 启发平滑 broken-N 候选；本项目试了低自由度版本，但第 14 节证据不支持采用。Ye 等 Data Mixing Laws 启发配比与规模可能耦合；由于附件 B 不含 17 域配比联合实验，本项目最终只用中心化加性桥接，未确认乘法/规模变化律。Chang 等质量有效 token 工作启发 $\text{effective_power}/\exp$ ；Goyal 等提示质量作用可能依赖资源量，因而测试 Q×D；最终这些候选均未胜过 Q×N。Biderman 等 Pythia 文献帮助解释同族检查点高度相关。文献提出某机制与本项目数据实际证明该机制是两回事。

B.1 质量代理补充图

以下图像分别展示领域质量区间、扩展样本去重后的分布核查、冲突率和指标相关结构。图中的质量分仍是固定规则下的代理量。




图 5-1 七域质量代理与条件区间




图 5-2 扩展样本去重后的质量分布




图 5-3 质量组间冲突率




图 5-4 质量信号相关结构

B. 2 配比模型补充图

配对改善图与逐域图对应主文的总体指标和域级权衡。局部置换图只表示既有配方支持域内的预测关联。




图 6-1 配比模型配对 RMSE 差




图 6-2 1B 验证域的 RMSE 变化




图 6-3 训练支持域附近的配比效应

B.3 选定链完整候选表

该表为相同训练与回顾性测试协议下的模型比较，保留 CLR 样条在 1M 更好、1B 退步的权衡。

模型	OOF RMSE	1M RMSE	60M RMSE	1B RMSE	判定
v2_champion	0.33401	0.270179	1.5959	2.70211	REPLACED
alr_elasticnet	0.318377	0.254346	1.59242	2.68871	NEW_CROSS_QUESTION_CHAMPION
ilr_ridge	0.351029	0.282204	1.59457	2.65676	REJECT_CROSS_SCALE_UPGRADE
alr_pls	0.542107	0.480686	1.62823	3.15623	REJECT_CROSS_SCALE_UPGRADE
clr_spline	0.252219	0.208173	1.56141	2.73571	REJECT_CROSS_SCALE_UPGRADE

B.4 跨评价集配对重抽样

相同配方的 1M 与 60M 结果不当作独立测试；本表保留各集内部的成对变化与区间。

评价集	配方数	RMSE 改善	下界	上界	正改善比例
train_nested_oof	512	0.0156324	0.0122545	0.0192701	1.0
test_lm	256	0.0158337	0.0104655	0.0210375	1.0
test_60m	256	0.00347948	-0.00176917	0.00871561	0.904
test_1B	64	0.0134057	0.00782303	0.0187954	1.0
est_10b	63	-0.00491975	-0.0129204	0.0031952	0.122
est_70b	63	-0.00488263	-0.0131789	0.00310284	0.1155

附录 C 问题二补充实验

本附录记录来源数据、历史候选与最终质量项的边界。

C.1 B 组预处理

项目不存在单独的 `data_audit_b.py`：审计实现于 `problem2/run_problem2.py:audit`。它遍历 B 文件，记录行数、列名、单元格缺失、整行重复、同 (N,D) 的重复、同 `run_id,steps` 检查点重复、来源类别以及 N,D,L,Q 范围，输出 `data_audit_b.csv`。B2 有 3,087 个缺失单元格，核心 $N,D, \text{val_loss}$ 仍可用于验证；B1 的核心字段无缺失、无整行重复。B6 的同 N,D 重复 315 次是设计上的多质量档，不是应删除的脏数据。

`quality_dataset_overlap.csv` 显示 B6/B7 同键 360 点，B7/B8 同键 224 点，B6/B8 同键 160 点。V1/V2 均用 (N,D,Q) 键从 B7 中剔除 B6 旧点，从 B8 中剔除 B7 旧点，得到 `B7_new=90`、`B8_new=1,480`。注意 B6/B8 的 160 个同键点虽然没有被当作新的验证样本，却被 V2 特意做同点冲突诊断。V2 的 `run_v2.py:diagnostics` 还输出残差、单调性、B1 小数精度与参数 profile。单位直接使用原始列中的 B，不另做 log 参数化；幂项在 V1 的 `classic` 中通过 `exp(-a*log(N))` 计算以保持数值稳定。

C.2 早期加性质量候选

V1 `run_problem2.py:fit_quality` 固定 B1 的 5 个 $N-D$ 参数，在 B6 单独估计 G, κ ；`quality` 函数比较 additive、指数有效 token、幂有效 token 的两阶段 / 联合方式，按 B6 BIC 和复杂度选中 `additive/two_stage`。`generalized_scaling.py:predict_ndq` 实现

$$L_A = L_{ND} + G_A(1 - Q_B)^{\kappa_A} + \lambda_p A_p(\mathbf{p}), \quad G_A = 0.362175024, \kappa_A = 0.990735089.$$

Q_B 升高使 $1 - Q_B$ 下降、惩罚缩小； $Q_B = 1$ 时退化为经典律。B6 RMSE 0.076068、BIC -1843.037；B7_new RMSE 0.059515；B8_new RMSE 1.392571，明确未达到预设条件。V1 参数与序列化模型在 `quality_scaling_params.csv`、`outputs/models/final_generalized_scaling.joblib`。它是后续比较的 Model A，不再是当前最终推荐 Q 结构。

C.3 文献与候选对应

本文引用文献的作用是说明模型结构和验证设计的来源，数值结论仍由附件 A、B、C 和本项目运行结果给出。不同研究使用的训练语料、模型架构与评测指标不尽相同，因此文献中的系数不直接进入本题的回归或优化。

研究	与本文对应的问题	本文实际采用的要点
Aitchison[1]	17 域比例满足总和为一	用 ALR 坐标描述相对配比，并检查参考域与零替换的影响
DataComp-LM[2]	文本信号与训练效用之间的验证	固定质量代理规则，保留人工盲评和受控训练的后续校准接口
RegMix[3]	小规模配方对候选配比的筛选	以 1M 配方训练预测器，单独报告跨规模评价
Hoffmann 等[4]	参数与 Token 的预算分配	使用低维经典标度律作为可解释基线
Pythia[5]	同模型族检查点的规律分析	按完整参数规模组留出，区分同族与跨来源误差
Data Mixing Laws[6]	配比响应与规模响应的连接	保留 λ_p 情景参数，并要求共同观测锚点
Gadre 等[7]	预训练损失与任务能力的连接	为 C6 拟合单调有界桥接，评价按家族隔离
Ho 等[8]	算力与时间项的历史分解	将时间项解释为模型内对照量，并核对观测前沿方向

在配方评价中，A4/A5 的 512 个样本足以训练低维代理并进行嵌套交叉验证，但它们均处于 1M 训练尺度。选定模型在 1M 和 1B 的 pooled 误差均低于冻结 Ridge，跨尺度绝对偏移则提示需要单独处理规模校准。因而论文使用 $f_A(\mathbf{p}) - f_A(\mathbf{p}_0)$ 作为跨问接口，而非迁移原始绝对 Loss。这一处理与组成数据坐标及配方代理的研究动机相容，具体有效范围仍由本项目的既定测试表限定。

在质量项评价中，B6/B7 的半合成生成机制使候选结构可以在相同口径下比较。 $Q_B \times N$ 的留组改善说明加入规模依赖有助于拟合该机制；B8 的同输入异标签对照则界定了跨机制统一函数的适用条件。文献中的数据筛选收益、有效 Token 定义与本题 Q_B 的测量方式不同，因此论文未把这些外部数值用作模型参数。

在能力分析中，六项完整基准的主指标与 C8 逐任务汇总具有较高秩相关，支持用统一分数进行本题前沿描述。C6 的家族分组误差和严格开放口径的季度样本数同时决定了桥接与时间结论的解释范围。长期情景采用冻结原点，分别改变算力增长和时间项；这一设计能够展示模型假设的影响，却不为各情景赋予主观概率。

C.4 补充诊断图

图 8-1 对照来源间的 $N - D$ 原始预测差；图 8-2 展示选定质量项随参数规模的条件响应；图 8-3 展示同输入机制诊断。相关数值以附录中的表格为准。




图 8-1 标度律来源间的预测比较




图 8-2 质量条件项与参数规模




图 8-3 B8 来源机制诊断

C.5 最终质量模型完整得分

模型	B6 训练 RMSE	B6 留 N RMSE	B7 新点 RMSE	BIC
additive			0.0595153	
effective_power			0.10557	
effective_exp			0.0796015	
saturating			0.0595213	
quality_data			0.0589004	
quality_model			0.0421271	

C.6 N - D 候选的组外与外源原始误差

同源留 N 误差与不同来源的 raw 误差应分开解读。

模型	B1 留 N	B2 raw	B4 raw	B5 raw	BIC
classic	0.00015118	1.24308	0.292667	0.197595	-20729.3
interaction	0.000152316	1.24308	0.292666	0.197596	-20722.6
compute_ratio	0.0976042	1.31283	0.317119	0.181741	-5993.22
broken_N	0.000151737	1.24308	0.292666	0.197571	-20720.9
classic_huber	0.00015118	1.24308	0.292667	0.197595	-20729.3

模型	B1 留 N	B2 raw	B4 raw	B5 raw	BIC
classic_soft_ll	0.00015118	1.24308	0.292667	0.197595	-20729.3
classic_relative	0.000149346	1.24307	0.292662	0.197602	-20721
classic_log	0.000150116	1.24308	0.292665	0.197598	-20728

C.7 来源条件校准的标签使用

该表的 20pct 协议消耗目标来源前段标签；与 C.7 的零样本 raw 评价性质不同。

来源	协议	校准行	留出行	RMSE	选择标记
B2	raw	203	826	1.0331	
B2	intercept_20pct	203	826	0.788919	
B2	affine_20pct	203	826	0.695515	
B2	logD_20pct	203	826	0.367362	
B2	nested_selected_20pct	203	826	0.367362	logD_20pct
B4	raw	12	45	0.248204	
B4	intercept_20pct	12	45	0.221161	
B4	affine_20pct	12	45	0.0916461	
B4	logD_20pct	12	45	0.161231	
B4	nested_selected_20pct	12	45	0.0916461	affine_20pct
B5	raw	9	35	0.188934	
B5	intercept_20pct	9	35	0.218046	
B5	affine_20pct	9	35	0.161882	
B5	logD_20pct	9	35	0.189887	
B5	nested_selected_20pct	9	35	0.218046	intercept_20pct

附录 D 问题三敏感性分析

上界、成本与联合参数重抽样均为条件检验，不作为真实世界概率分布。

D.1 资源配置补充图

图 9-1 展示观测域、扩展边界及自由外推配置的条件差异；图 9-2 展示质量成本下的转折预算；图 9-3 对比共同可行域的风险准则；图 9-4 展示预算成本构成。




图 9-1 三种外推层级的条件配置




图 9-2 质量投入结构点




图 9-3 共同可行政策的后悔值比较




图 9-4 算力预算构成

D. 2 E0/E1/E2 完整配置表

预算	等级	N(B)	D(B)	Q_B	Loss	预算率
1e+19	E0_empirical	0.311385	3.9555	0.724121	3.18042	1
1e+19	E1_moderate_3x	0.311385	3.9555	0.724121	3.18042	1
1e+19	E2_free_scaling	0.311385	3.9555	0.724121	3.18042	1
1e+22	E0_empirical	5.43315	245.591	1	2.1547	1
1e+22	E1_moderate_3x	5.43315	245.591	1	2.1547	1
1e+22	E2_free_scaling	5.43315	245.591	1	2.1547	1
1e+24	E0_empirical	11.965825	299.893	1	2.09338	0.0255706

预算	等级	N(B)	D(B)	Q_B	Loss	预算率
1e+24	E1_moderate_3x	35.897475	899.679	1	1.9794	0.223535
1e+24	E2_free_scaling	39.5618	3657	1	1.916	1

D.3 联合参数重抽样分位数

分位数仅描述选定 B1/B6 参数与指定成本结构下的条件波动，不能包住外推结构误差。

预算	变量	重抽样数	5%	中位	95%
1e+19	N_B	200	0.307918	0.311569	0.329118
1e+19	D_B	200	3.65731	3.95113	4.01541
1e+19	Q_B	200	0.720333	0.7247	0.741321
1e+19	loss	200	3.17543	3.18102	3.18928
1e+20	N_B	200	0.932937	0.955558	1.00253
1e+20	D_B	200	9.51946	10.6946	11.2635
1e+20	Q_B	200	0.943538	0.961611	1
1e+20	loss	200	2.70076	2.7026	2.70361
1e+22	N_B	200	5.43064	5.4332	5.43524
1e+22	D_B	200	245.505	245.589	245.695
1e+22	Q_B	200	1	1	1
1e+22	loss	200	2.15469	2.15471	2.15472
1e+24	N_B	200	39.5156	39.5632	39.5912
1e+24	D_B	200	3654.32	3656.87	3661.21
1e+24	Q_B	200	1	1	1
1e+24	loss	200	1.91597	1.916	1.91605

D.4 高预算上界敏感性

表中上界倍率是人为证据边界：达到上界的配置并未证明该倍率最合理。

上界倍率	N(B)	D(B)	Q_B	Loss	预算率
1.0	11.965825	299.893	1	2.09338	0.0255706
2.0	23.93165	599.786	1	2.0171	0.100082
3.0	35.897475	899.679	1	1.9794	0.223535
5.0	59.829125	1499.465	1	1.93807	0.617262
10.0	48.3611	2998.93	1	1.91643	1
not_applicable	39.5618	3657	1	1.916	1

附录 E 问题四补充结果

历史分析与未来条件情景采用不同时间含义：2025Q1 的严格口径 n=2 只作描述。

E.1 数学模型与计算链

E.2 规模/技术贡献分解

以首末季度 p95 为锚，对固定算力和固定时间两条路径作对称 Shapley。模型隐含总变化 6.84 分，其中算力 2.15 分（31.5%）、剩余时间项 4.69 分（68.5%）；组织 cluster bootstrap 95% 区间分别 [1.09,2.96] 和 [-5.93,43.44]。实际观测 p95 变化 -2.80 分，与模型隐含方向不一致，因此不能把上述百分比当作稳健主结论或因果份额。历史不满12个月，最近12/24个月贡献无法计算。技术等效算力由 $10^{(\text{betaT} \Delta t/\text{betaC})}$ 求出，仅作为敏感性。

E.3 算力增长放缓情景

情景 S1/S2/S3 将近期对数增长率乘 1/0.5/0.25；技术 T1/T2/T3 将剩余时间斜率乘 1/0.5/0。倍率是假设而非概率。以 C4 最后完整季度的 p90 FLOP 为起点；情景包络不是统计置信区间。

E.4 历史前沿

采用严格开放权重样本每季度能力 p95。四个季度样本数分别为 22、16、5、2；2025Q1 未达到预先设置的 $n \geq 5$ 解释门槛。因此仅发布前沿的描述数值，不能断言最近季度涨跌。宽松继承匹配的 C2 样本给出相反方向，只作敏感性。

E.5 规模与时间

在同 32 个发布、13 个组织的分组交叉验证中，仅算力模型 RMSE=7.052，算力加时间结构模型 RMSE=7.103。因此历史预测对照用仅算力模型。结构模型可按固定假设生成算力/时间 Shapley 分解，但其隐含前沿变化 6.84 分，与观测变化 -2.80 分方向相反；历史贡献份额不作为实证结论。

E. 6 Loss 到能力的桥接

采用高可比权重 1、中可比权重 0.35 的单调有界 logistic 桥接。C6 的 75 条记录来自 23 个家族，其中高可比仅 7 条且同属一个家族。家族隔离五折 RMSE=11.864 分。isotonic 的 RMSE=11.451，但增益的家族重抽样区间跨零，且端点平台不稳定；保留较简单 logistic。桥接输入须标注 Loss 来源及可比性。

E. 7 决策与短期参照

问题三给出 E0/E1/E2 条件策略，默认展示 E1 的 3× 限制，但不能称其为已证明的唯一高预算最优。三个月短期目标只有两个，其中一个目标季度 n=2。持平基线 MAE=3.947，直接时间趋势 MAE=6.477；这支持把持平作为风险参照，不能据此升级长期预测器。

E. 8 12/24 个月情景

原点为 2025-01-31，目标日期为 2026-01-31 和 2027-01-31。每个期限为三种算力增长 × 三种技术时间项设定，共九条。12 个月情景中位数范围 [33.47, 50.81]；24 个月为 [36.88, 71.13]。这是情景包络，不是经 12/24 个月回测校准的预测区间。各行条件 bootstrap 区间及锚点 n=2 的警示见 ../winner_chain/problem4/outputs/tables/frontier_forecast_12m_24m.csv。以当前日期理解，2026-01-31 已是历史日期；本次严格使用冻结的 2025-01-31 数据截点，不把后见资料混入回测。

E. 9 能力前沿补充图

图 10-1 呈现逐任务汇总与六基准主指标的对应；图 10-2 展示 C6 可比性分层；图 10-3 展示季度算力前沿；图 10-4 展示冻结原点下的九情景范围。情景图用于展示假设变化，不代表已校准的未来覆盖概率。




图 10-1 逐任务与六基准能力




图 10-2 Loss - 能力桥接的可比性分层




图 10-3 历史算力前沿




图 10-4 能力前沿条件情景

E. 10 严格季度前沿原表

季度	样本数	p95 分数
2024Q2	22	33.0183
2024Q3	16	38.1163
2024Q4	5	32.3839
2025Q1	2	30.2222

E. 11 12/24 月完整条件情景

每行由算力增长和剩余时间项假设组合得到；50%、80%、95% 条件区间未覆盖未来来源变化，也未经相应期限直接回溯校准。

月数	算力情景	时间情景	中位分数	80% 下界	80% 上界
12	continuation	continuation	50.8107	34.2951	76.499
12	continuation	half_rate	47.433	33.9789	65.5197
12	continuation	flat	44.0786	30.4726	58.0563
12	moderate_slowdown	continuation	43.3656	27.7453	70.1043
12	moderate_slowdown	half_rate	40.0795	27.0739	59.6369
12	moderate_slowdown	flat	36.8803	24.7937	50.1395
12	strong_slowdown	continuation	39.7321	24.1199	68.7268
12	strong_slowdown	half_rate	36.5436	24.3395	55.6194
12	strong_slowdown	flat	33.469	22.4763	46.5134
24	continuation	continuation	71.1279	46.6432	95.2701
24	continuation	half_rate	65.2761	46.9711	84.2229
24	continuation	flat	58.9232	42.6873	72.2964
24	moderate_slowdown	continuation	57.5136	32.0541	92.1289
24	moderate_slowdown	half_rate	50.8107	33.935	75.0713
24	moderate_slowdown	flat	44.0786	30.394	57.8994
24	strong_slowdown	continuation	50.0864	24.9986	90.6524
24	strong_slowdown	half_rate	43.3656	27.1077	70.1759
24	strong_slowdown	flat	36.8803	24.8817	50.1877

附录 F 核心代码说明与来源核对

问题一选定规格与逐域比较见 rebuild/problem1/；问题二参数、组外误差和来源诊断见 rebuild/problem2/；问题三政策表、KKT 和质量转折见 rebuild/problem3/；问题四季度前沿与情景包络见 rebuild/problem4/ 和 rebuild/final_review/outputs/。选定链上下游关系记录在 rebuild/final_review/verification/selected_lineage.json。正式提交的支撑附件应只保留参赛队复核后的必要程序与结果，具体清单以最终提交的支撑附件为准。

F.1 图表与计算产物核对

本稿的图表分别连接到质量评分、配比模型、条件标度律、预算优化和能力前沿的已保存产物。图 5-1 - C4 对应 A 组质量分和冲突定义；图 6-1 - D3 对应配比模型的配对误差与逐域权衡；图 8-1 - F3 对应 B 组来源比较；图 9-1 - 9-4 对应 E0/E1/E2、质量成本与共同可行决策；图 10-1 - H4 对应能力测量、桥接、算力和情景。每张图在正文或附录附近标明适用数据层，避免将估算标签与观测标签并列解释为相同证据。

图 F1 展示质量与规模项的条件关系，图 F2 展示标度律拟合的范围，图 F3 展示严格口径能力前沿，图 F4 展示情景与观测的区分。图中的方法和参数均来自本项目既有脚本与选定链。




图 F1 质量与规模的条件关系




图 F2 B1 条件标度律




图 F3 严格口径能力前沿




图 F4 预测情景的条件范围

正式提交时，参赛队应以附件中的 CSV/JSON 和代码重新生成最终图表，并检查每张图的横纵轴、单位、样本数与图注。模型系数的精度、情景预算与前沿日期均需与最终 PDF 对应；如使用更新数据，应重新运行相应上游和下游模块，再重新冻结论文中的数字。

F.2 选定链代码入口

- 问题一：rebuild/problem1/run_tournament.py、export_selected.py、verify_tournament.py。
- 问题二：rebuild/problem2/run_tournament.py、predict_final.py、verify_tournament.py。
- 问题三：problem3_v2/run_v2.py、methods.py、verify_v2.py，以及最终复赛表。
- 问题四：rebuild/winner_chain/problem4/data_pipeline.py、bridge_model.py、history_forecast.py、mechanism.py、verify_problem4.py。

以上路径用于赛后复核。正式提交的支撑附件应由参赛队检查匿名和必要性。

F.3 AI 工具使用说明

本稿由 AI 助手依据项目已有数据、代码、审阅记录和参考文献草拟。参赛队应核对模型推导、参数、表格、图注、文献与最终措辞，并按竞赛规则补充实际工具名称、型号、使用环节及人工复核信息。[待补充]